UNIVERSIDAD POLITÉCNICA DE MADRID

ESCUELA TÉCNICA SUPERIOR
DE INGENIEROS DE TELECOMUNICACIÓN



GRADO EN INGENIERÍA Y SISTEMAS DE DATOS

TRABAJO FIN DE GRADO

DISEÑO DE UNA HERRAMIENTA PARA EL ANÁLISIS COMPARATIVO DE LA BÚSQUEDA DE INFORMACIÓN ENTRE MODELOS DE LENGUAJE Y BUSCADORES TRADICIONALES EN ESPAÑA

JOSÉ MARÍA MARTÍN RODRÍGUEZ

2026

Grado en Ingeniería y Sistemas de Datos

TRABAJO DE FIN DE GRADO

Título: Diseño de una herramienta para el análisis comparativo de la búsqueda de información entre modelos de lenguaje y buscadores tradicionales en España

Autor: José María Martín Rodríguez

Supervisión técnica: D. Javier Conde Díaz

Supervisión académica: D. Javier Conde Díaz

Departamento: Ingeniería de Sistemas Telemáticos

MIEMBROS DEL TRIBUNAL

Presidente: ----------

Vocal: ----------

Secretario: ----------

Suplente: ----------

Los miembros del tribunal arriba nombrados acuerdan otorgar la calificación de:

Fecha de lectura: ----------

UNIVERSIDAD POLITÉCNICA DE MADRID

ESCUELA TÉCNICA SUPERIOR
DE INGENIEROS DE TELECOMUNICACIÓN



GRADO EN INGENIERÍA Y SISTEMAS DE DATOS

TRABAJO FIN DE GRADO

DISEÑO DE UNA HERRAMIENTA PARA EL ANÁLISIS COMPARATIVO DE LA BÚSQUEDA DE INFORMACIÓN ENTRE MODELOS DE LENGUAJE Y BUSCADORES TRADICIONALES EN ESPAÑA

JOSÉ MARÍA MARTÍN RODRÍGUEZ

2026

Resumen

La Inteligencia Artificial (IA) ha experimentado un notable avance durante la última década. En este contexto, los modelos de lenguaje de gran escala (Large Language Models, LLM) han adquirido un papel central debido a su capacidad para generar texto coherente y contextualizado a partir de una entrada determinada, así como para procesar y acceder a grandes volúmenes de información.

Cuando se hace referencia a la Inteligencia Artificial (IA), la mayoría de las personas la asocian de manera inmediata con asistentes virtuales como ChatGPT, Gemini o DeepSeek. Sin embargo, el verdadero interés reside en comprender los mecanismos y tecnologías que hacen posible el funcionamiento de estas herramientas. En este sentido, los modelos de lenguaje de gran escala desempeñan un papel fundamental, ya que han permitido la evolución de los tradicionales chatbots basados en reglas rígidas hacia sistemas capaces de comprender el contexto, interpretar el lenguaje natural y ejecutar tareas complejas mediante técnicas de inferencia estadística.

Una vez comprendido esto, surgen diversos interrogantes en torno al funcionamiento de los modelos de lenguaje. Entre ellos, destaca la necesidad de analizar cuáles son las fuentes de datos que alimentan estos sistemas y mediante qué mecanismos acceden, procesan y recuperan la información empleada en la generación de sus respuestas. Asimismo, resulta pertinente cuestionar la posible existencia de sesgos inherentes en dichos modelos, el grado de fiabilidad de la información proporcionada y las similitudes o diferencias que presentan respecto al funcionamiento de motores de búsqueda tradicionales como Google.

Estas y otras cuestiones constituyen el eje central del presente estudio y serán abordadas a lo largo de este trabajo.

El presente Trabajo de Fin de Grado posee como objetivo analizar y comparar el funcionamiento de los distintos sistemas de búsqueda y recuperación de información disponibles actualmente en Internet. Para ello, se contrastarán los resultados obtenidos mediante un motor de búsqueda tradicional como Google con las respuestas generadas por un modelo de lenguaje como GPT-4o mini. También se evaluarán las diferencias entre las respuestas proporcionadas por el modelo cuando dispone de acceso a Internet mediante herramientas de búsqueda y cuando opera únicamente con la información adquirida durante su entrenamiento.

El estudio permitirá determinar, ante consultas idénticas o equivalentes, hasta qué punto los resultados proporcionados por ambos sistemas presentan similitudes o diferencias significativas. Para ello, se analizarán aspectos como la diversidad de las respuestas obtenidas, el orden de aparición de los resultados y el grado de coincidencia entre ellos. Con este propósito, se emplearán consultas locales centradas en España, como por ejemplo “¿Cuáles son los mejores restaurantes asiáticos en Madrid?”.

Palabras clave

LLM, Motores de búsqueda, Recuperación de información, SEO, comparativa, análisis de datos, Google, GPT-4o mini, España

Summary

Artificial Intelligence (AI) has experienced remarkable progress over the last decade. In this context, Large Language Models (LLMs) have acquired a central role due to their ability to generate coherent and contextualized text from a given input, as well as to process and access large volumes of information.

When referring to Artificial Intelligence (AI), most people immediately associate it with virtual assistants such as ChatGPT, Gemini or DeepSeek. However, the real interest lies in understanding the mechanisms and technologies that make these tools possible. In this regard, Large Language Models play a fundamental role, as they have enabled the evolution of traditional rule-based chatbots into systems capable of understanding context, interpreting natural language, and performing complex tasks through statistical inference techniques.

Once this context is understood, several questions arise regarding the functioning of language models. Among them, it is important to analyze the data sources that feed these systems and the mechanisms through which they access, process, and retrieve the information used to generate their responses. Likewise, it is relevant to question the possible existence of inherent biases in these models, the degree of reliability of the information they provide, and the similarities or differences they present in comparison with traditional search engines such as Google.

These and other issues constitute the central focus of this study and will be addressed throughout this work.

The aim of this Bachelor's Thesis is to analyze and compare the functioning of the different information search and retrieval systems currently available on the Internet. To this end, the results obtained through a traditional search engine such as Google will be contrasted with the responses generated by a language model such as GPT-4o mini. Differences between the responses provided by the model when it has Internet access through search tools and when it operates solely with the information acquired during its training will also be evaluated.

The study will determine, for identical or equivalent queries, to what extent the results provided by both systems present significant similarities or differences. To achieve this, aspects such as the diversity of the obtained responses, the order in which the results appear, and the degree of overlap between them will be analyzed. For this purpose, local queries focused on Spain will be employed, such as: "Which are the best Asian restaurants in Madrid?".

ETSIT UPM

Keywords

Large Language Models (LLM), Search Engines, Information Retrieval, SEO, Comparative Study, Data Analysis, Google, GPT-4o mini, Spain

Agradecimientos

En primer lugar, quiero agradecer a mi tutor, Javi, por su dedicación, paciencia y orientación a lo largo de todo este trabajo. Sus comentarios y ayuda han sido claves para llevar este proyecto a buen puerto.
A mi familia, por estar siempre ahí y por acompañarme en estos cuatro años de carrera con apoyo incondicional.
Y por último a mis compañeros habituales de proyectos a lo largo de la carrera, a Pablo, Diego, Tapia, y Mario; por las tareas compartidas, las risas y el trabajo en equipo.
Gracias a todos los que habéis formado parte de este camino.

Índice

1 Introducción y objetivos **1**

1.1 Introducción 1

1.2 Objetivos 2

1.2.1 Objetivos generales 2

1.2.2 Objetivos específicos 2

2 Estado del arte **4**

2.1 Historia y evolución de la IA 4

2.2 Modelos de Lenguaje de Gran Escala (LLM) 6

2.2.1 Evolución histórica 6

2.2.2 Arquitectura transformer 7

2.2.3 Entrenamiento y datos 9

2.2.4 Modelos relevantes 9

2.3 Recuperación de información en Internet 10

2.4 Motores de búsqueda tradicionales 12

2.4.1 Historia 12

2.4.2 Funcionamiento general 13

2.4.3 SEO 14

2.5 LLM como herramientas de búsqueda 15
2.5.1 Recuperación aumentada por generación (RAG) 16
2.5.2 Búsqueda web integrada 16
2.5.3 Limitaciones: alucinaciones y conocimiento desactualizado 17
2.6 Comparativas previas entre LLM y motores de búsqueda 17

3 Desarrollo **19**

3.1 Diseño del estudio y enfoque comparativo 19
3.2 Generación del pool de consultas 21
3.2.1 Consultas 21
3.2.2 Subconjunto de análisis 22
3.3 Herramientas y APIs utilizadas 23
3.3.1 DataForSEO 23
3.3.2 API de OpenAI 24
3.4 Obtención y procesamiento de respuestas 24
3.5 Herramienta web comparativa 26
3.5.1 Backend 26
3.5.2 Frontend 27

4 Resultados **30**

4.1 Análisis del pool de 10.000 consultas locales 30
4.1.1 Introducción al análisis comparativo 30
4.1.2 Similitud global entre sistemas 30
4.1.3 Análisis por categoría temática 32
4.1.4 Universo de dominios y top dominios por fuente 32

4.1.5 Dominios exclusivos de cada fuente 34
4.1.6 Casos frontera: alta y baja coincidencia 35
4.2 Análisis del subconjunto de 200 consultas populares 36
4.2.1 Similitud global y comparativa con las 10.000 consultas 36
4.2.2 Análisis por categoría temática 38
4.2.3 Top dominios por fuente 38
4.2.4 Análisis de posiciones y orden de resultados 40
4.2.5 Análisis profundo de clasificación de rankings 43
4.3 Limitaciones del análisis 45

5 Conclusiones y líneas futuras 46
5.1 Conclusiones 46
5.2 Líneas de trabajo futuro 47

Bibliografía 49

Anexos 54
A Aspectos éticos, económicos, sociales y ambientales 54
A.1 Introducción 54
A.2 Descripción de impactos relevantes relacionados con el proyecto 54
A.3 Análisis detallado de alguno de los principales impactos 55
A.4 Trasfondos 56
B Presupuesto económico 58
C Repositorio de Código 59

Listado de figuras

2.1 Timeline de los hitos más importantes de la IA (Figura generada con Claude AI) 6

2.2 Representación gráfica de la arquitectura Transformer (Figura generada con Claude AI) 8

2.3 Timeline de los hitos más importantes en la historia de los motores de búsqueda (Figura generada con Claude AI) 13

3.1 Cuota de mercado de los motores de búsqueda en el último año en todo el mundo [1] 19

3.2 Cuota de mercado de los motores de búsqueda en el último año en España [1] . 20

3.3 Número de enlaces por consulta 26

3.4 Número de enlaces por consulta (preguntas populares) 27

3.5 Arquitectura de SearchLab 28

3.6 Interfaz1 de modo de búsqueda general 29

3.7 Interfaz2 de modo de búsqueda general 29

3.8 Interfaz de modo de búsqueda de rastreo 29

4.1 Gráfico comparativo de métricas entre sistemas 31

4.2 Heatmap que mide la similitud sesgada de dominio por categoría 32

4.3 Dominios más representados por GPT 33

4.4 Dominios más representados por Google 33

4.5 Dominios exclusivos de GPT 34
4.6 Dominios exclusivos de Google 35
4.7 Gráficas comparativas entre métricas de similitud 37
4.8 Heatmap que mide la similitud sesgada de dominio por categoría 38
4.9 Dominios más representados por GPT 39
4.10 Dominios más representados por Google 40
4.11 Pearson para Google 41
4.12 Coeficiente pearson para GPT 41
4.13 Consultas con mayor coincidencia entre los GPT 43

Listado de tablas

3.1 Distribución de consultas por categoría 22

3.2 Distribución de consultas populares por categoría 23

4.1 Comparación de métricas entre sistemas 31

4.2 Métricas de similitud y coincidencia entre sistemas 36

4.3 Coinicidencias por dominio y por URL 37

4.4 URLs coincidentes entre Google, GPT con Search y GPT sin Search 37

4.5 Presencia de Wikipedia en los resultados de cada motor 39

4.6 Diferencias en las posiciones de los dominios coincidentes entre motores 42

4.7 Diferencia media de posiciones y correlación de Pearson por categoría (Los resultados positivos en la diferencia media van a favor de GPT con Search, los negativos a favor de GPT sin Search) 42

5.1 Presupuesto económico del Trabajo Fin de Grado 58

Introducción y objetivos

1.1 Introducción

Para comenzar y antes de repasar la historia completa de la IA y los LLM, centrémonos en la pionera empresa OpenAI. Esta corporación se fundó en 2015 y en los últimos años se había centrado en desarrollar modelos de lenguaje a los que denominó GPT, comenzando con GPT-1 en junio de 2018. Sin embargo, el verdadero punto de inflexión de los LLM fue la aparición y llegada de GPT-3 en 2020. Su repercusión y resultados trascendieron por primera vez al gran público. Este modelo contaba con 175.000 millones de parámetros y mostró el gran potencial que tenían este tipo de herramientas en diversos campos. Esto catapultó la IA, que habiendo comenzado como un campo de investigación académica empezó a convertirse en una tecnología a disposición de los usuarios.

En noviembre de 2022 la empresa volvió a innovar lanzando ChatGPT, el cual era el primero de una nueva generación de interfaces conversacionales basadas en LLM. Esta herramienta pionera utilizaba GPT-3.5 como su motor. ChatGPT tuvo una gran acogida, con una de las curvas de adopción (curva de Rogers) más rápidas de la historia de la tecnología, en apenas unos días ya había alcanzado los 100 millones de usuarios [2].

Por otro lado, los motores de búsqueda tradicionales llevan siendo las herramientas más utilizadas para acceder a información desde que inició el siglo XX. Estos dejaron de lado a los sistemas utilizados anteriormente como pueden ser las bibliotecas, mucho más transitadas antes de la creación de Internet y estas herramientas; archivos de periódico o enciclopedias físicas. Actualmente muy pocas personas cuentan con una enciclopedia en su casa, compran el periódico diariamente o van a la biblioteca para informarse (su uso ha evolucionado a préstamo de libros o sitio de estudio). Los ejemplos más famosos de buscadores son Google (de la propia empresa de Google), Bing (de Microsoft), Baidu (también coloquialmente denominado el Goggle Chino), DuckDuckGo o Yandex. Su funcionamiento se basa en la indexación masiva de páginas web y en algoritmos de ranking que tienen en cuenta técnicas de optimización (Search Engine Optimization, SEO).

Viendo lo que supuso la aparición de los motores de búsqueda para la recuperación de información, todavía está por determinar el impacto que tendrán los LLM y los asistentes virtuales, tecnologías que, en términos relativos, presentan una aparición reciente en el ámbito tecnológico. La irrupción de los LLM en este campo nos deja bastante dudas sobre si servirán para sustituir a los buscadores tradicionales o para ser herramientas complementarias. Las dudas que surgen al pensar en estos sistemas tienen implicaciones directas en la calidad y fiabilidad de la información que millones de usuarios reciben a diario. Sin embargo, para poder resolver estas dudas deberíamos basar nuestras respuestas en hechos objetivos y no opiniones sesgadas.

Debido a esto para poder basar nuestras respuestas en hechos deberíamos tener una cantidad de estudios comparativos empíricos que evalúen los resultados de estos dos sistemas que se postulan como posibles alternativas. Actualmente para evaluar los modelos de lenguaje se utilizan métodos y métricas aisladas, como pueden ser la precisión, la coherencia o la capacidad de razonamiento. Pero verdaderamente no se ponen en relación con los buscadores tradicionales.

En el contexto de consultas locales con fuerte componente geográfico, por ejemplo ir de viaje y decidir en que restaurante comer o en que hotel alojarse, este vacío de estudios comparativos en español llega a ser relevante en cierta forma. En este caso, los buscadores podrían llegar a estar condicionados por estrategias de SEO local mientras que los LLM pueden no reflejar la actualidad del mercado por patrones desarrollados en el entrenamiento.

Cabe añadir que la posibilidad de activar el acceso de los LLM a Internet abre una nueva dimensión al análisis, con el objetivo de evaluar los beneficios o desventajas de esta opción o el mayor alineamiento o desalineamiento con los resultados de los buscadores tradicionales.

1.2 Objetivos

1.2.1 Objetivos generales

El objetivo general del presente Trabajo de Fin de Grado es cubrir la falta de estudios comparativos mencionada anteriormente con un enfoque cuantitativo y reproducible. Se comparará el funcionamiento de los motores de búsqueda y de los LLM, utilizando como representantes Google y GPT-4o mini (con búsqueda activada y desactivada) de cada una de las 2 herramientas respectivamente.

1.2.2 Objetivos específicos

Para alcanzar el objetivo general, se ha desglosado en distintos subobjetivos:

→ Investigar el funcionamiento de los modelos de lenguaje y los motores de búsqueda tradicionales. Comprender sus mecanismos de recuperación de información, así como el papel del SEO en la ordenación y relevancia de los resultados.

→ Generar un dataset de consultas centradas en búsquedas locales en España, complementado con un subconjunto de preguntas de alta popularidad para reforzar el análisis comparativo.

→ Evaluar comparativamente los resultados obtenidos por distintos sistemas midiendo diferencias en términos de diversidad, orden de aparición y grado de coincidencia entre los

resultados proporcionados por motores de búsqueda y modelos de lenguaje.

→ Implementar un sistema web que permita al usuario introducir consultas y obtener respuestas comparadas de los distintos sistemas, junto con métricas de coincidencia y puntuaciones basadas en el orden de aparición.

→ Extraer conclusiones sobre el rendimiento comparado de los sistemas. Identificar ventajas, limitaciones y escenarios de uso óptimos para cada enfoque de recuperación de información, aportando evidencia empírica sobre el papel de los LLM en este contexto.

Estado del arte

2.1 Historia y evolución de la IA

Los fundamentos matemáticos de lo que conocemos hoy como Inteligencia Artificial se remontan a inicios del segundo tercio del siglo XX, sin embargo su origen como disciplina científica se sitúa a mediados de siglo. Entre los años 1931, y 1936 Alan Turing y Kort Godel sentaron las bases teóricas sobre las que se construiría el campo, formalizando el concepto de computación y los límites del razonamiento automático [3]. En 1943 los científicos Warren McCulloch y Walter Pitts abrieron la puerta al paradigma conexionista que décadas más tarde dominaría la disciplina con su artículo seminal *"A Logical Calculus of the Ideas Immanent in Nervous Activity"*. En este, propusieron el primer modelo matemático de una neurona artificial y demostrando que una red de estas neuronas podía realizar y computar cualquier función lógica [4]. No mucho después, en 1950, el doctor Alan Turing propuso el conocido **Test de Turing** en su célebre artículo *"Computing machinery and intelligence"*. Esta prueba servía para evaluar si una máquina podía actuar de forma indistinguible de los humanos, dotando así a la máquina de la calificación de inteligente [3].

Sin embargo, el término de Inteligencia Artificial no apareció hasta el año 1956 durante la conferencia de Dartmouth organizada por John McCarthy, Marvin Minsky, Claude Shannon y Nathaniel Rochester [5]. Este evento marcó el nacimiento oficial de la IA como disciplina académica independiente y estableció la agenda y los pasos futuros a seguir en su progreso. En los años sucesivos, los sistemas basados en reglas lógicas y representación explícita del conocimiento dominaron la investigación, cabe destacar como uno de los primeros y más influyentes el General Problem Solver de Newell y Simon (1957) [6]. De todas formas, las limitaciones de este enfoque se evidenciaron pronto debido a la complejidad del mundo real y a su pobre capacidad de generalización.

La historia de la IA se caracteriza también por los 'inviernos de la IA', este termino se utiliza para definir periodos en el tiempo de escepticismo y drástica reducción de financiación, se produjeron principalmente en torno a 1974 y 1987 [3]. Estas etapas de estancamiento tienen un origen claro y manifiesto, el fracaso de soluciones excesivamente optimistas realizadas por los investigadores que no supieron anticipar la verdadera dificultad de los problemas abordados. No obstante, en estos periodos de retroceso también se produjeron grandes avances para el posterior resurgimiento. En 1986, David Rumelhart, Geoffrey Hinton y Ronald Williams introdujeron el algoritmo de retropropagación del error (backpropagation) permitiendo así que las redes neuronales multicapa se pudiesen entrenar de forma eficiente [7]. Sincrónicamente Hinton y Sejnowski desarrollaron **las máquinas de Boltzmann**, precursoras de los modelos generativos modernos [3].

Otro de los hitos más importantes y conocidos de este sector fue la victoria del sistema desarrollado por IBM, **Deep Blue**, frente al campeón mundial de ajedrez, Gary Kasparov, en el año 1997; demostrando así el potencial de las máquinas en tareas de razonamiento lógico [8]. Coetáneamente, Sepp Hochreiter y Jürgen Schmidhuber publicaron las redes de memoria a largo y corto plazo (Long Short-Term Memory, **LSTM**), una arquitectura recurrente que tenía como objetivo resolver el problema del desvanecimiento de gradiente (problema presenciado en el entrenamiento de redes neuronales), colocándose como el estándar para el procesamiento de secuencias [9].

El verdadero punto de inflexión hacia la IA moderna llegó a principios del siglo XXI, impulsado por 3 factores clave: el aumento de la capacidad de cómputo (protagonizado por la irrupción de las unidades de procesamiento gráfico, GPU, para tareas de entrenamiento de redes neuronales), la disponibilidad de datos masivos digitales con la expansión de Internet y el desarrollo de nuevas arquitecturas de aprendizaje profundo [4]. En 2006, se introdujo el 'deep learning' de la mano de Geoffrey Hinton demostrando como el preentrenamiento no supervisado servía para entrenar redes neuronales multicapa de forma efectiva [10].

En 2012, mediante la victoria del sistema AlexNet en la competición ImageNet Large Scale Visual Recognition Challenge (**ILSVRC**) colocó al deep learning en el centro de la investigación en IA. Desarrollado por Alex Krizhevsky, Ilya Sutskever y Geoffrey Hinton en la Universidad de Toronto, **AlexNet**, un modelo de clasificación de imágenes, redujo la tasa de error de forma drástica respecto a sus competidores [11]. A partir de este momento, el sector sufrió una aceleración desmesurada.

Entre 2013 y 2017 surgieron diversos avances que constatarían las bases del deep learning moderno. En 2014 Ian Goodfellow propuso las redes generativas antagónicas (**GAN**), generando imágenes realistas desde ruido aleatorio [12]. Las redes residuales (**ResNet**), introducidas en 2015, innovaron con las conexiones de salto permitiendo el entrenamiento de redes neuronales profundas [13]. Las redes neuronales de grafos (**GNN**) extendieron el aprendizaje profundo a datos estructurados en forma de grafo [14]. En 2016, se produjo otra victoria importante, el sistema **AlphaGo** de DeepMind derrotó al campeón mundial del juego Go, Lee Sedol, juego que se consideraba inabordable por las máquinas debido a su complejidad combinatoria [15].

El año 2017 marcó un antes y un después en el procesamiento de lenguaje natural con la publicación de *"Attention Is All You Need"* por Vaswani et al., que introdujo la arquitectura Transformer basada en mecanismos de atención [16]. Esta arquitectura se convirtió rápidamente en el estándar en el cual se basarían los modelos de lenguaje posteriores debido a su escalabilidad y su capacidad de paralelización.

En 2018 Google publicó **BERT** (Bidirectional Encoder Representations from Transformers) rompiendo récords en tareas de comprensión de lenguaje natural [17]. A su vez OpenAI entraba en juego presentando GPT-1 [18] y con la evolución previamente explicada en la introducción de este trabajo y desencadenando una carrera tecnológica entre las principales empresas del sector [19].

Modelos como GPT-5, Gemini, LLaMA, DeepSeek... han continuado ampliando las fronteras de lo posible [14] y consolidando los LLM como la tecnología más innovadora de la presente década.

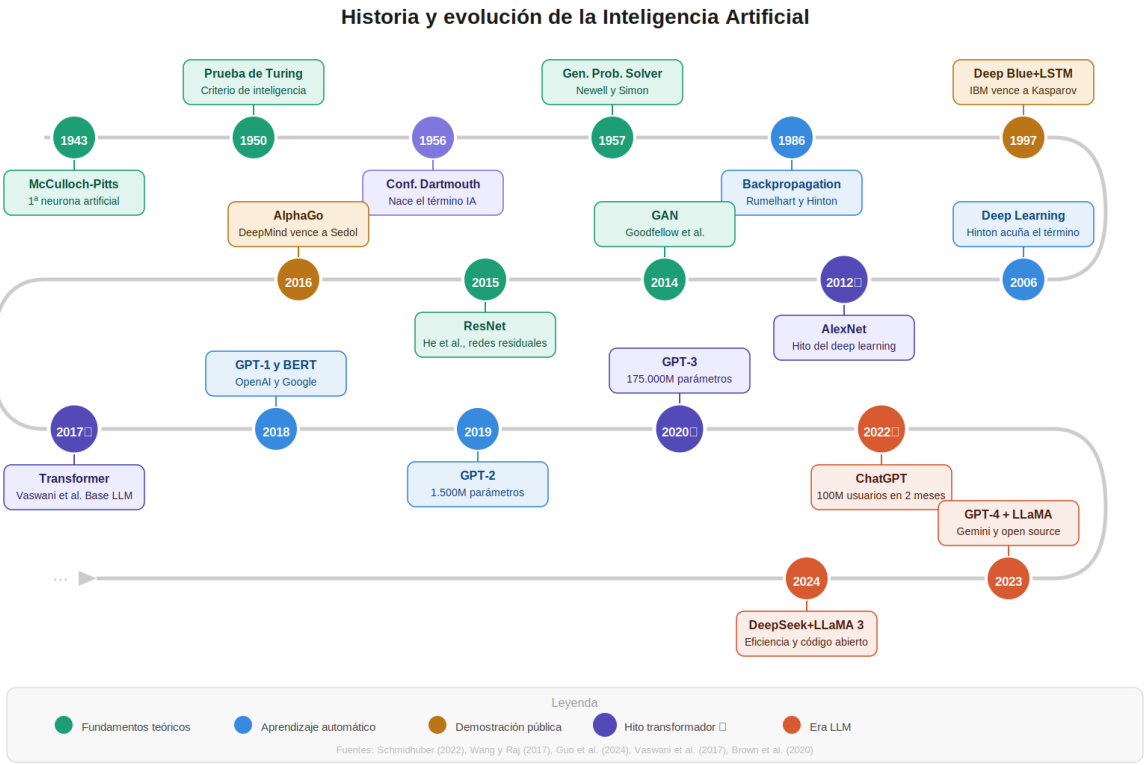


Figura 2.1: Timeline de los hitos más importantes de la IA (Figura generada con Claude AI)

2.2 Modelos de Lenguaje de Gran Escala (LLM)

2.2.1 Evolución histórica

Los modelos de lenguaje de gran escala tienen sus orígenes en la investigación en procesamiento de lenguaje natural (NLP), mas su forma actual está muy ligada a la arquitectura Transformer introducida en 2017. Las primeras versiones se trataban de modelos estadísticos, basados en n-gramas. Su funcionamiento residía en modelar la probabilidad de una palabra respecto a las utilizadas anteriormente, sin embargo su capacidad para capturar dependencias a larga distancia era muy limitada [19]. Otro de los primeros enfoques eran los chatbots de reglas rígidas y

plantillas predefinidas que simulaban conversaciones, como por ejemplo el sistema informático **ELIZA** desarrollado entre 1964 y 1966 en el MIT (Instituto Tecnológico de Massachusetts) por Joseph Weizenbaum. No fue hasta mediados de la década de 2010 cuando se empezaron a vislumbrar avances significativos codificando relaciones semánticas en espacios vectoriales continuos transformando el lenguaje en números a través de representaciones vectoriales [19]. Destacando herramientas como **Word2Vec** o **GloVe**.

Como se ha explicado anteriormente en 2018 se publicaron 2 modelos que definirían el paradigma dominante en NLP. BERT introdujo el preentrenamiento bidireccional, este consistía en permitir al modelo capturar el contexto tanto a la izquierda como a la derecha de cada token, otorgando así una comprensión del lenguaje mucho más rica. GPT-1 por su parte adoptó una arquitectura decoder-only basada en Transformers y demostró que un preentrenamiento sobre datos masivos y un posterior ajuste supervisado a tareas específicas dotaban al modelo de una eficiencia mucho mayor [17][18].

Al año siguiente, OpenAI presentó GPT-2, este modelo contaba con 10 veces más de parámetros que su predecesor (1.500 millones), su capacidad de generación de texto era tan elevada que la empresa dudó en publicarlo al completo por posibles riesgos en su uso. En 2020 llegó el salto definitivo con GPT-3, esta tercera versión contaba con 175.000 millones de parámetros y demostró capacidades nuevas e inesperadas como la resolución de tareas nuevas sin entrenamiento específico mediante el denominado aprendizaje en contexto (few-shot learning) [20]. Desde entonces, el sector inició una carrera frenética y competitiva que se mantiene ininterrumpida hasta la actualidad.

2.2.2 Arquitectura transformer

Esta arquitectura es la base sobre la que se construyen todos los LLM modernos, fue propuesta por Vaswani et al. en 2017. Su principal innovación fue sustituir la recurrencia secuencial de arquitecturas anteriores por un mecanismo de atención que actúa en paralelo sobre toda la secuencia de entrada permitiendo un entrenamiento mucho más eficiente [16].

El componente central es el mecanismo de atención multi-cabeza (multi-head attention). Para cada token de la secuencia se calculan 3 vectores distintos, la consulta (Query, Q), la clave (Key, K) y el valor (Value, V). La atención se halla obteniendo el producto escalar normalizado entre las consultas y las claves, aplicado como peso sobre los valores, identificando que partes de la secuencia son relevantes para representar cada uno de los tokens. El uso de múltiples cabezas sirve para capturar diferentes relaciones semánticas y sintácticas simultáneamente [16]. Dicho de manera más sencillo, cada palabra compara lo que busca con lo que ofrecen las demás, decide cuáles son las más reveladoras y mezcla su información, esto lo hace a la vez para entender distintas cosas a la vez aumentando así la eficiencia.

La arquitectura original se conformaba por un encoder y un decoder. Con el encoder se procesa

la entrada y se generan representaciones contextualizadas y con el decoder se genera la salida de forma inversa, teniendo en cuenta su propia salida previa como la representación del encoder [16]. Sin embargo, para tareas de generación de texto abierto el encoder carece de utilidad. Es por esto que los LLM modernos modelan la probabilidad del siguiente token a generar únicamente con la secuencia de tokens previos y prescindiendo del encoder [16].

Los embeddings son otro de los aspectos claves de esta arquitectura. Antes de entrar en las capas de atención, cada uno de los tokens se convierten a vectores numéricos capturando su significado semántico. A estos embeddings se les suman los embeddings posicionales que marcan la ubicación de cada token en la secuencia [16]. Las arquitecturas modernas han evolucionado hacia codificaciones posicionales relativas y rotacionales (**RoPE**) que permiten una mejor generalización a secuencias de longitud variable [19].

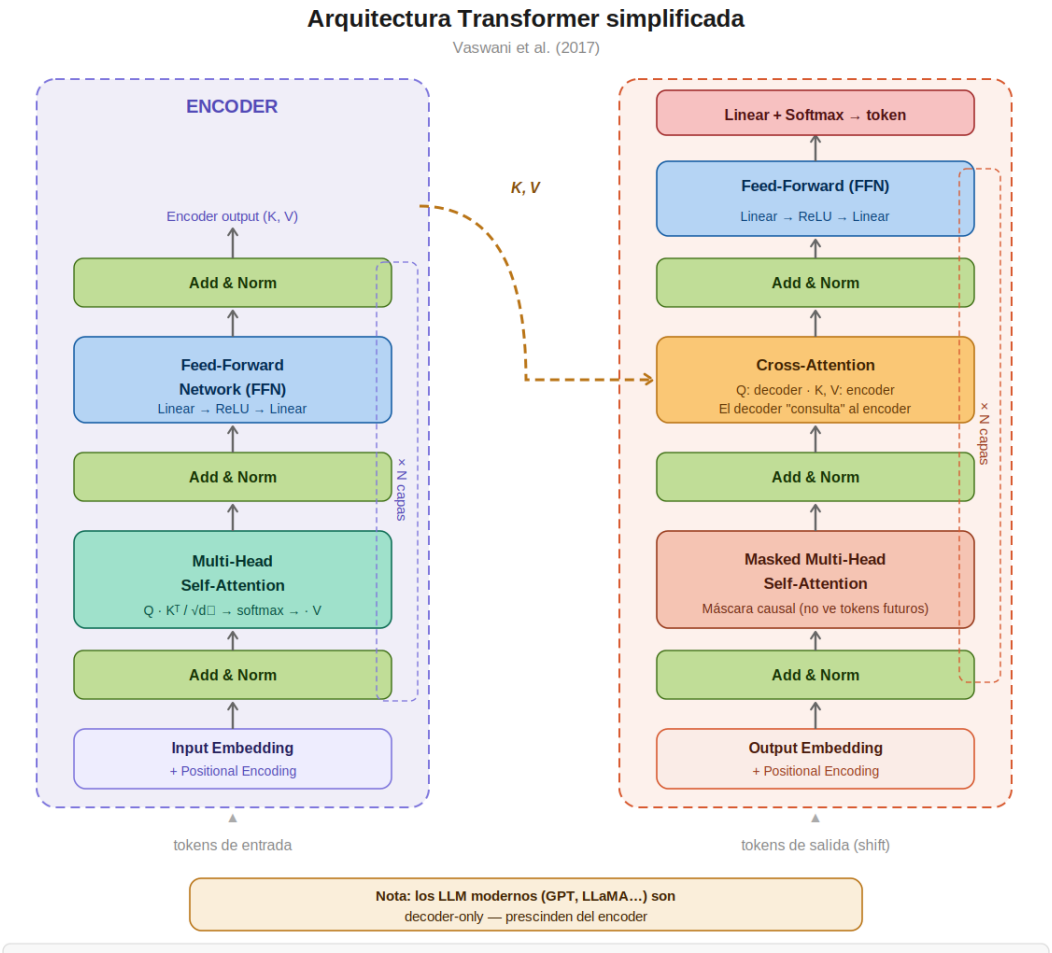


Figura 2.2: Representación gráfica de la arquitectura Transformer (Figura generada con Claude AI)

2.2.3 Entrenamiento y datos

Cuando se quiere entrenar un LLM moderno hay que pasar por varias fases sucesivas, desde la adquisición de conocimiento general hasta la alineación y personalización con las necesidades de los usuarios. Se pueden distinguir en tres fases principales, sin contar con la recopilación y el preprocesamiento de los datos utilizados para el entrenamiento:

→ **Preentrenamiento:** El modelo aprende representaciones ricas del lenguaje a partir de grandes cantidades de texto no etiquetado mediante el objetivo de predicción del siguiente token. Esta fase tiene un coste en cómputo bastante elevado, por ejemplo el coste de entrenar GPT-3 fue de varios millones de dólares [20]. El modelo adquiere conocimiento factual, capacidad de razonamiento, habilidades lingüísticas y, en cierta medida, la capacidad de realizar tareas para las que no ha sido explícitamente entrenado.

→ **Ajuste fino supervisado (SFT):** El modelo preentrenado se adapta a tareas o dominios específicos sobre conjuntos de datos etiquetados más reducidos y específicos. El modelo se especializa sin perder el conocimiento adquirido en el preentrenamiento y obtiene la capacidad de entender y responder preguntas en el formato adecuado [19].

→ **Aprendizaje por refuerzo a partir de retroalimentación humana (RLHF):** Esta técnica consiste en entrenar un modelo de recompensa mediante el cual los humanos evalúan sus respuestas, este aprende a premiar las respuestas correctas optimizando así su algoritmo para maximizar las recompensas a obtener, estos algoritmos son de aprendizaje por refuerzo como PPO (Proximal Policy Optimization). Este mecanismo ,introducido por OpenAI en 2022 a través de InstructGPT, ha demostrado ser la base del éxito de ChatGPT [21]. Sin embargo presenta claras limitaciones, como el criterio de los evaluadores humanos o un fenómeno conocido como 'reward hacking' mediante el cual el modelo aprende a maximizar las recompensas sin mejorar la calidad de las respuestas [22].

2.2.4 Modelos relevantes

El ecosistema actual de grandes modelos de lenguaje se puede dividir en 2 subgrupos, el primero engloba a los desarrollados por grandes corporaciones tecnológicas, mientras que el segundo hace referencia a los desarrollados por la comunidad investigadora de código abierto. Algunos de los ejemplos más relevantes son:

- **OpenAI:** Su familia de modelos ha evolucionado significativamente desde GPT-4 hacia sistemas más avanzados con capacidades de razonamiento mejoradas y mayor integración en entornos reales. El 1 de mayo de 2026 lanzaron su último modelo, GPT-5.5.Estos modelos destacan por su versatilidad y su adopción masiva en aplicaciones empresariales y de automatización [23][24].

- **Google DeepMind:** Cuentan con la familia de modelos Gemini, ampliando significativamente la capacidad de contexto y el procesamiento multimodal [25][26].

- **Anthropic:** Los modelos Claude están evolucionando con un fuerte enfoque en la alineación y la fiabilidad. Se caracterizan por su buen rendimiento en tareas de razonamiento prolongado, análisis de documentos extensos y generación de código, manteniendo una alta consistencia en sus respuestas [27]. Su último modelo de uso público es Claude Opus 4.7.

- **xAI:** Con Grok como modelo por excelencia introducen enfoques experimentales como sistemas multi-agente y una integración directa con plataformas digitales [28]. Su lanzamiento más reciente es Grok 4.

- **DeepSeek:** Sus modelos destacan especialmente por su eficiencia en entrenamiento y su rendimiento en tareas de razonamiento matemático y programación. DeepSeek-R1, en particular, ha demostrado capacidades de razonamiento comparables a las de los modelos más avanzados de OpenAI con un coste de entrenamiento significativamente inferior [29]. Actualmente, su último lanzamiento es DeepSeek-V4.

- **Open Weight:** Aquí aparecen modelos como LLaMA de Meta, Mistral o Qwen (DeepSeek entra también en esta categoría). Estos modelos permiten su ejecución local y ofrecen ventajas en términos de coste y control [30][31][32].

2.3 Recuperación de información en Internet

La recuperación de información (Information Retrieval, IR) consiste en representar, almacenar, organizar y recuperar información relevante a partir de grandes colecciones de documentos en respuesta a las necesidades de un usuario [33]. Con el crecimiento ingente de información digital disponible en la web y en Internet, esta disciplina ha adquirido un papel fundamental en el funcionamiento de los motores de búsqueda modernos [34].

Los modelos clásicos de recuperación de información pueden dividirse en 3 familias distintas:

- **Booleano:** Esta primera familia es la más antigua, representa documentos y consultas como conjuntos de términos y emplea operadores de álgebra booleana (AND, OR, NOT) para determinar la relevancia. Su limitación principal es la representación tan pobre que hace, una representación binaria indicando si el documento es relevante o no lo es. Esta representación no es útil para consultas complejas [33].
- **Vectorial:** Esta familia fue introducida por Salton en 1975 y se basa en representar los documentos y las consultas en vectores dentro de un espacio multidimensional de términos. La relevancia se calcula mediante la similitud del coseno entre dichos vectores [34] permitiendo así introducir el grado de relevancia para ordenar los resultados. Sobre

este modelo se desarrollaron esquemas de ponderación de términos como **TF-IDF** (Term Frequency–Inverse Document Frequency), fórmula matemática que sirve para saber qué palabras son realmente importantes en un documento específico, sin dejarse engañar por las palabras que más se repiten en todos los textos.

- **Probabilístico:** Esta última familia cuenta con **BM25** (Best Match 25) de Robertson y Jones (1976) como su modelo más influyente. Para estimar si un documento es relevante para una consulta incorpora la frecuencia de términos y la longitud del documento en función de su puntuación (penaliza documentos muy largos en favor de cortos y específicos) [35]. Sigue siendo utilizado como línea base en numerosos sistemas de recuperación actuales debido a su robustez y eficacia.

En 1998, Brin y Page revolucionaron la recuperación de información web introduciendo el concepto de puntuación de importancia independiente de la consulta, basada en el análisis de la topología del grafo de enlaces hipertextuales de la web [36]. Esta innovación se implementó mediante el algoritmo PageRank que sostiene que una página web es importante si otras páginas importantes enlazan a ella. Formalmente el PageRank de una página web se define de forma recursiva como la suma ponderada de los PageRank de las páginas que la enlazan, ajustada por el número de enlaces saliente de cada una de ellas [37].

A partir de 2019 con la llegada del deep learning y los LLM preentrenados basados en la arquitectura Transformer la recuperación de información sufrió un cambio radical. Surgió la recuperación neuronal densa (**Neural IR**),que representa documentos y consultas como vectores densos en un espacio semántico latente, capturando relaciones de significado que los modelos léxicos como BM25 son incapaces de detectar [38]. Explicado de manera más sencilla, antes con BM25 se tenía la necesidad de encontrar documentos con las palabras de las consultas exactamente, ahora en vez de buscar las palabras exactas se relacionaban semánticamente las palabras para buscar palabras con significado parecido [38].

Karpukhin et al. demostraron con el modelo **DPR** (Dense Page Retrieval) [39] en 2020 que en tareas de respuestas abiertas codificadores densos basados en BERT eran más eficaces que BM25. Modelos como **ColBERT** introdujeron interacciones de nivel de token entre consulta y documento, mejorando la precisión a costa de mayor coste de memoria y **SPLADE** (Sparse Lexical and Expansion Model) combinó las ventajas de la recuperación dispersa y la semántica neuronal en un único modelo.

En la actualidad, los sistemas de recuperación de información cuentan con arquitecturas híbridas con el objetivo de equilibrar la eficiencia y la precisión viable a escala web. Combinan recuperadores léxicos eficientes en una primera fase con reordenadores neurales más costosos en una segunda fase.

2.4 Motores de búsqueda tradicionales

2.4.1 Historia

Un motor de búsqueda es un sistema de software diseñado para poder realizar búsquedas en Internet. Su historia está muy ligada a la historia de la propia web. Antes de que existieran las herramientas de búsqueda, para poder encontrar la información que deseabas en Internet había que conocer la dirección exacta del recurso o depender de recomendaciones directas entre usuarios. Esto impedía que los recursos llegaran a gran cantidad de personas por la dificultad que implicaba encontrarlos.

En 1990 Alan Emtage, Bill Heelan y Peter Deutsch en la Universidad McGill de Canadá desarrollaron **Archie**, el primer sistema de búsqueda de la historia. Fue creado como un índice de archivos FTP que permitía a los usuarios hacer búsquedas por Internet, no reconocía las búsquedas con lenguaje natural ni indexaba el contenido de los archivos, funcionaba mediante comandos UNIX (grep) para buscar nombres de archivos en una base de datos actualizada mensualmente. Además, para poder ver si el archivo era realmente una respuesta a lo que se estaba buscando había que descargarlo [40].

Poco después, en 1991 y 1993 surgieron **Verónica** (Very Easy Rodent-Oriented Net-wide Index to Computerized Archives) y **Judghead** (Jonzy's Universal Gopher Hierarchy Excavation and Display) que extendieron el mismo principio utilizado por Archie a los servidores Gopher, un sistema de distribución de información distribuido, basado en menús y texto y desarrollado por la universidad de Minnesota en 1991 [41].

El punto de inflexión ocurrió en 1991 cuando Tim Berners-Lee en el CERN (Organización Europea para la Investigación Nuclear) presentó la **World Wide Web** tras dos años trabajando en ella. Esta herramienta permite visualizar páginas web interconectadas usando los protocolos HTTP, HTML y URLs [36]. Tras ello en 1993 **Jumpstation** se convirtió en el primer sistema en combinar las tres funciones de un motor de búsqueda moderno, rastreo de páginas, indexación y recuperación de resultados [42]. Ese mismo año, **Wandex** fue el primer rastreador web que indexaba el contenido completo de las páginas. En 1994, la aparición de **WebCrawler** supuso un nuevo avance al permitir buscar cualquier palabra en el cuerpo completo de un documento, no solo en su título o URL [42]. También en 1994 Jerry Yang y David Filo en la Universidad de Stanford fundaron **Yahoo!**, un directorio web de categorías web curadas manualmente. Se convirtió en la principal puerta a Internet y a la búsqueda de webs, aunque su dependencia de editores humanos lo hacía incapaz de escalar al ritmo de crecimiento de la web [43][44].

En 1995 **AltaVista** se convirtió en el primer motor de búsqueda capaz de indexar el texto completo de páginas a escala web, introduciendo la búsqueda en lenguaje natural [45]. Sin embargo ordenaba sus resultados utilizando únicamente frecuencia de palabras clave, presencia

en el título y proximidad de términos, haciéndolo vulnerable a técnicas de manipulación como relleno de palabras clave [36].

El cambio definitivo llegó en 1998 con Larry Page y Sergey Brin, en Stanford. Fundaron **Google** presentando una innovación principal, el algoritmo Page Rank, dando a entender que la estructura de enlaces que apuntaban a cada página era igual de importante que su contenido para ver la importancia de la misma [37]. Esta idea, permitió a Google destacarse respecto de sus competidores y lo catapultó a una posición de dominio en el sector, acaparando prácticamente todo el mercado global de búsqueda [46]. En 2009, Microsoft lanzó Bing como alternativa provocando que Google continuara refinándose con actualizaciones algorítmicas como Panda en 2011 para penalizar el contenido de baja calidad, Penguin en 2012 dirigida contra estrategias manipuladoras de enlaces y Hummingbird en 2013 con objetivo de mejorar la comprensión semántica de las consultas [47].

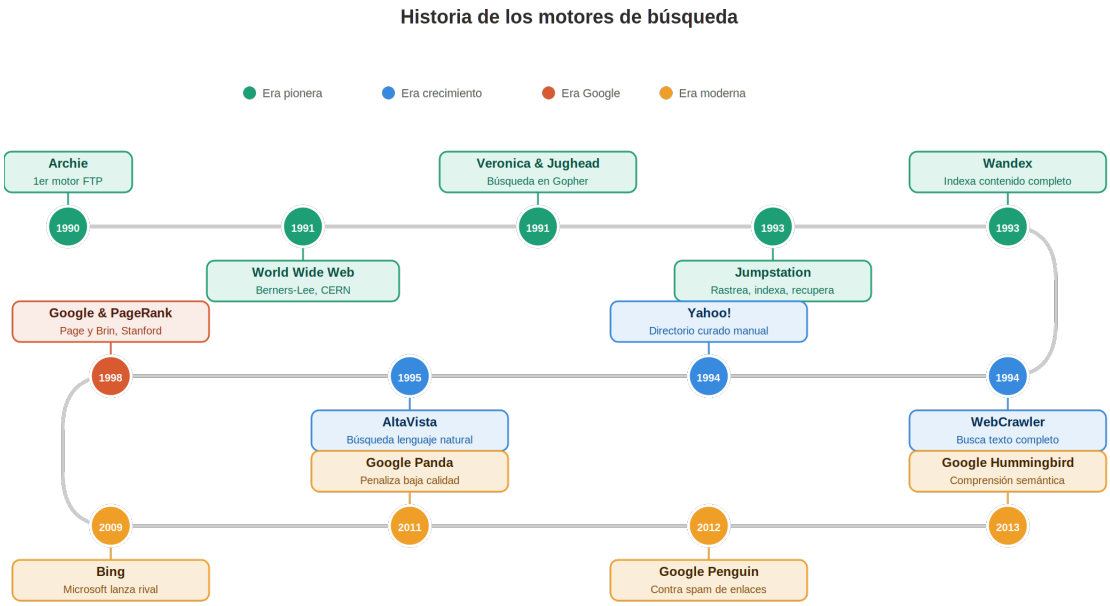


Figura 2.3: Timeline de los hitos más importantes en la historia de los motores de búsqueda (Figura generada con Claude AI)

2.4.2 Funcionamiento general

El funcionamiento de un motor de búsqueda moderno puede dividirse en cuatro etapas secuenciales [48]:

→ **Rastreo (Crawling):** Programas automatizados denominados rastreadores web, arañas o bots desplegados por los motores de búsqueda (Googlebot en el caso de Google por ejemplo). Se dedican a recorrer la web siguiendo hipervínculos entre páginas y descargando su contenido. Para ello los motores asignan a cada dominio un presupuesto de rastreo que determina con qué frecuencia y profundidad se visitan sus páginas [49]. Los administradores de sitios web pueden influir en este proceso mediante archivos robots.txt, indicando al rastreador qué secciones visitar, y mediante sitemaps XML que proporcionan un mapa completo de las URLs del sitio. En webs con JavaScript, el rastreador debe renderizar la página para ver el contenido final que entregaría al usuario, añadiendo un extra de complejidad y coste [50].

→ **Indexación:** Esta etapa sirve para una vez descargado el contenido de una página poder analizar, extraer los términos relevantes y almacenar en una estructura de datos denominada índice invertido una tabla para cada término del vocabulario, registrando que documentos lo contienen y con qué frecuencia [34]. En otras palabras, se genera un diccionario de términos. Este índice permite recuperar documentos relevantes en milisegundos ante cualquier consulta. Además, se indexan metadatos como la fecha de publicación, la autoridad del dominio, la velocidad de carga o la adaptación a dispositivos móviles. Características que posteriormente se utilizarán en el ranking.

→ **Ranking:** En esta fase se ordenan los documentos candidatos recuperados a través del índice para presentarlos al usuario que ha introducido la consulta. Los sistemas utilizados no tienen una fórmula fija, se basan en modelos de aprendizaje automático entrenados sobre gran cantidad de pares consulta-documento etiquetados por evaluadores humanos [49]. Aparte del contenido de los documentos para estos rankings se tienen en cuenta los metadatos indexados en la fase anterior y cada vez más las señales de comprensión semántica derivadas de modelos de lenguaje. Cada motor de búsqueda utiliza sus propios algoritmos de ranking que van siendo actualizados a lo largo del tiempo (pueden llegar a sufrir miles de actualizaciones en un año) y pueden alterar el posicionamiento de millones de páginas [46].

→ **Servicio de resultados:** En esta fase final los motores de búsqueda presentan las webs al usuario ordenadas según las fases anteriores.

2.4.3 SEO

La optimización para motores de búsqueda es el conjunto de técnicas y prácticas orientadas a mejorar la visibilidad y el posicionamiento de un sitio web en los resultados orgánicos de los motores de búsqueda. Un análisis de 10 estudios realizados entre 2022 y 2024 concluyó que la implementación de estrategias SEO está directamente relacionada con incrementos significativos en el posicionamiento orgánico y el tráfico web [51]. Estas técnicas se agrupan en dos grandes categorías, on-page y off-page.

Las **on-page** actúan sobre el propio contenido y la estructura de la página. Incluyen la optimización de palabras clave, esto consiste en analizar los términos y palabras que los usuarios suelen utilizar en sus consultas e incorporarlos estratégicamente en el título, los encabezados y el cuerpo del texto. La mejora de la estructura semántica del HTML, la optimización de metaetiquetas, la mejora de velocidad de carga, la adaptación a dispositivos móviles y la mejora de la experiencia de usuario en general.

Las **off-page** actúan sobre factores externos al sitio, como por ejemplo la construcción de enlaces entrantes, que consiste en obtener que otras webs reputadas enlacen a tu propia web incrementando así la puntuación de PageRank [51].

Se podría decir que los resultados de los motores de búsqueda están sesgados por el uso del SEO. Esto se debe a que no solo van a reflejar la relevancia intrínseca de un contenido, van a reflejar la capacidad de sus responsables para optimizarlo técnicamente. Este hecho puede favorecer a sitios web con mayores recursos para invertir en SEO o a personas con mayor conocimiento en el tema [52]. Este efecto se denomina sesgo de presentación o position bias, los usuarios tienden a confiar y hacer clic en los primeros enlaces asumiendo que son de mayor calidad, cuando en muchas ocasiones no es así [53]. Investigaciones recientes constatan que los resultados sesgados de los motores de búsqueda pueden influir en el pensamiento o en las opiniones de los usuarios sobre temas en los que no tienen opiniones previas consolidadas, a este fenómeno se le cataloga como Search Engine Manipulation Effect (SEME) [54].

Los propios motores de búsqueda reconocen que existe una tensión entre el SEO y la calidad de los resultados. Por un lado, ofrecen guías y herramientas para ayudar a optimizar las páginas; pero por otro, desarrollan algoritmos para detectar y penalizar las prácticas más agresivas o manipuladoras [52]. Esta dinámica puede llegar a ser relevante para el presente estudio, ya que los resultados obtenidos por los motores de búsqueda pueden estar condicionados por el nivel de optimización SEO de sus páginas más que por su relevancia real.

2.5 LLM como herramientas de búsqueda

La irrupción de los modelos de lenguaje de gran escala como herramienta de consulta de información plantea una nueva forma de recuperación de información que difiere totalmente de los motores de búsqueda tradicionales. Un LLM genera una respuesta con lenguaje natural sintetizando el conocimiento almacenado en sus parámetros durante el entrenamiento. En el caso de este trabajo el LLM genera una lista de webs en base a su conocimiento de entrenamiento, sin necesidad de generar esa respuesta en lenguaje natural.

2.5.1 Recuperación aumentada por generación (RAG)

El conocimiento almacenado por un LLM en sus pesos durante el entrenamiento (conocimiento paramétrico) tiene dos limitaciones fundamentales, puede estar desactualizado ya que se acota a la fecha de corte del corpus de entrenamiento y para poder actualizarlo se debe reentrenar el modelo completo, algo bastante costoso e inviable [55]. Con objetivo de superar estas dos limitaciones se desarrolló el paradigma RAG.

El funcionamiento del RAG se describe en tres fases. En la primera, cuando un LLM recibe una consulta un módulo de recuperación busca en una base de conocimiento externa los textos más relevantes para responder a la consulta (puede ser una colección de documentos, una base de datos vectorial o la propia web) [55]. Esta recuperación puede utilizar técnicas léxicas como BM25, técnicas densas basadas en embeddings o una combinación de ambas. En la segunda fase, se concatenan los fragmentos recuperados con la consulta original y se proporcionan al LLM como contexto adicional. Y en la tercera y última fase, el modelo genera una respuesta habiendo utilizado dicho contexto pudiendo así citar las fuentes utilizadas [56]. Mediante esta arquitectura el modelo puede responder a consultas con información actualizada y real sin necesidad de reentrenarse [55].

Los primeros sistemas RAG, como Naive RAG, recuperaban un número fijo de fragmentos y los concatenaban directamente. En los últimos años han evolucionado a arquitecturas más sofisticadas que reordenan los fragmentos recuperados, verifican su relevancia y generan iterativamente con múltiples rondas de recuperación (Advanced RAG). Incluso se han desarrollado configuraciones completamente modulares que permiten desglosar el proceso en componentes independientes, flexibles y personalizables; permitiendo así la adaptación, depuración y optimización de cada una de las fases (Modular RAG) [55].

2.5.2 Búsqueda web integrada

Una variante especialmente relevante es la integración de acceso a Internet en tiempo real dentro de los LLM. Ante una consulta del usuario el modelo lanza una o varias búsquedas web con las que obtiene los fragmentos más relevantes de las páginas encontradas y los incorpora en el contexto antes de generar la respuesta [48].

Este mecanismo asemeja el comportamiento de los modelos de lenguaje de gran escala al de los motores de búsqueda tradicionales. El sistema combina la capacidad de indexación y recuperación de la web característica de los buscadores con la capacidad de síntesis y generación de lenguaje. Esta claro que existen diferencias estructurales importantes, ya que Google únicamente devuelve una lista ordenada de enlaces y los LLM devuelven respuestas sintetizadas en lenguaje natural, asumiendo también la responsabilidad de síntesis y corriendo el riesgo de introducir errores [57]. En el caso de este trabajo al obtener por parte de los LLM una lista de webs ordenadas la principal diferencia va a residir en los algoritmos de ranking, ya

que los modelos no utilizarán algoritmos de PageRank como hacen los buscadores, se servirán de sus propias técnicas para ordenar las webs (relevancia semántica, probabilidad estadística, familiaridad del dominio, síntesis neuronal sobre resultados web).

A priori, las respuestas obtenidas en el estudio por el LLM sin búsqueda web activada carecerán de validez e importancia, ya que contarán con resultados desactualizados y en algunos casos hasta inventados. En cualquier caso, nos servirán para contrastar la teoría.

2.5.3 Limitaciones: alucinaciones y conocimiento desactualizado

Como hemos visto otra de las limitaciones es el conocimiento desactualizado, algo bastante problemático en dominios de rápida evolución como la tecnología, la actualidad política, o como en este estudio consultas sobre servicios locales como restaurantes, ferreterías, hoteles..., un LLM sin acceso a Internet puede desconocer nuevos establecimientos, cierres... [55].

Estas limitaciones contrastan con el funcionamiento de los motores de búsqueda tradicionales, que recuperan documentos reales y actualizados de la web sin necesidad de modificar su contenido trasladando al usuario la responsabilidad de evaluar su fiabilidad.

2.6 Comparativas previas entre LLM y motores de búsqueda

El interés por comparar el rendimiento de los LLM y los motores de búsqueda ha crecido vertiginosamente desde la irrupción de ChatGPT en 2022, aunque los estudios existentes son todavía incipientes y heterogéneos en cuanto a metodología, dominio de aplicación y métodos empleados.

Preferencias de usuario y casos de uso

Uno de los primeros estudios sistemáticos sobre preferencias de usuario fue llevado a cabo por Caramancion en 2024 [58], con una muestra de 100 usuarios estadounidenses evaluando 20 casos de uso distintos. Los resultados fueron que para consultas directas basadas en hechos los usuarios elegían motores de búsqueda y para tareas que requerían comprensión elegían LLM. Este hallazgo sugiere que ambos sistemas son complementarios y dependen del tipo de consulta que se necesite.

En una línea similar el estudio de Zhu en 2024 [59] sobre paradigmas evolutivos en búsqueda basada en tareas concluye que los sistemas LLM modernos han comenzado a responder consultas acompañando las respuestas con referencias a páginas web mejorando su credibilidad.

Calidad de las respuestas por dominio

Fernández-Pichel et al. en 2025 en un estudio publicado en *"npj Digital Medicine"* [60] compararon cuatro motores de búsqueda, siete LLM y variantes RAG ante 150 preguntas de salud. Los resultados mostraron que los motores de búsqueda respondían correctamente entre el 50 % y el 70 %, mientras que los LLM alcanzaban el 80 % de precisión, aunque su rendimiento era sensible a la formulación de la consulta. En el ámbito odontológico, un estudio publicado con preguntas ortodónticas obtuvo resultados similares [61].

Sin embargo, no todos los estudios son favorables a los LLM. Diversos estudios han encontrado que una proporción significativa de las referencias generadas o recuperadas por estos modelos no son verificables o no corresponden correctamente a las fuentes originales, incluso en dominios especializados como la medicina. En evaluaciones sistemáticas, se ha observado que los LLM pueden presentar tasas elevadas de errores en la recuperación de referencias y en la consistencia de sus citas, evidenciando problemas estructurales en su fiabilidad factual en contextos de alta exigencia [62][63].

Solapamiento de resultados entre LLM y Google

Los estudios más recientes que analizan el grado de coincidencia entre los dos sistemas revelan un solapamiento sorprendentemente bajo. Ahrefs en 2025 [64] en un análisis de 15.000 consultas, encontró que el solapamiento medio de citaciones entre los asistentes de IA y el top 10 de Google y Bing era de apenas el 11 %.

Un estudio en 2025 de Chatoptic [65] sobre 1.000 consultas en cinco sectores competitivos encontró que las marcas presentes en la primera página de Google aparecían en las respuestas de ChatGPT solo el 62 % de las veces, con una correlación de ranking prácticamente nula de apenas 0,034 con navegación web activada y 0,022 sin ella. Esto apunta a principios de selección y ordenación fundamentalmente distintos.

Profound en 2025 [66], en un análisis de dos tipos de consultas con cientos de ejecuciones por pregunta, halló solapamientos de URLs de entre el 8 % y el 12 % entre ChatGPT y Google.

En cuanto al mercado, SparkToro y Datos en 2025 [67] determinó que Google sigue reinando recibiendo aproximadamente 373 veces más búsquedas diarias que ChatGPT (14.000 millones frente a 37.500 millones).

La revisión de los estudios existentes muestra que la mayoría de ellos se centran en dominios anglosajones sin considerar el comportamiento de ambos sistemas ante consultas locales en español. Asimismo, muy pocos estudios analizan simultáneamente tres condiciones: motor de búsqueda tradicional, LLM con acceso a Internet y LLM sin acceso a Internet, lo que impide aislar el efecto del acceso a fuentes externas en tiempo real sobre la calidad y el solapamiento de los resultados. El presente trabajo pretende contribuir como evidencia empírica nueva a llenar los dos vacíos presentados.

Desarrollo

3.1 Diseño del estudio y enfoque comparativo

Como ya se ha explicado previamente el presente estudio adopta un enfoque empírico y cuantitativo con el objetivo de comparar el comportamiento de tres sistemas de recuperación de información ante un conjunto común de consultas en lenguaje natural. Los sistemas evaluados serán:

- **Google:** Como representante de los motores de búsqueda tradicionales basados en indexación y ranking algorítmico. La elección del mismo se debe a su posición dominante en la cuota de mercado global y a su papel central en la forma en que los usuarios acceden a la información en la web. Al ser el motor de búsqueda más utilizado (90 % de cuota de mercado en el mundo), sus resultados reflejan de manera significativa la experiencia real de la mayoría de los usuarios. Además, dado el alto grado de sofisticación de sus algoritmos de ranking permite establecer un punto de referencia relevante para el análisis. En España el porcentaje de cuota de mercado es incluso mayor alcanzando más del 93 %.

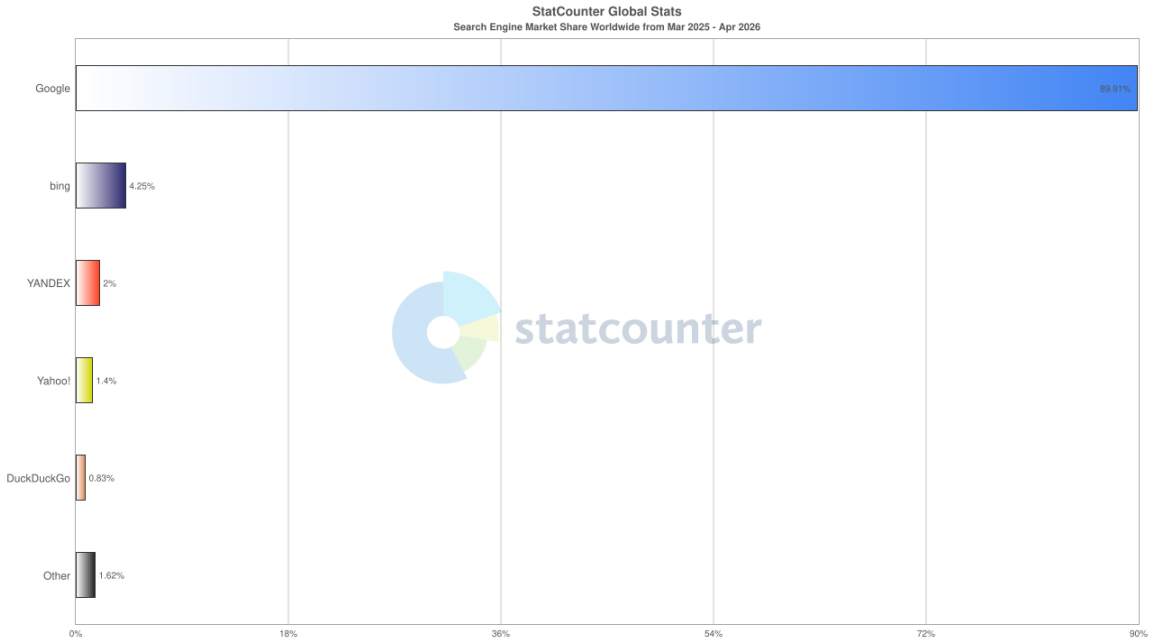


Figura 3.1: Cuota de mercado de los motores de búsqueda en el último año en todo el mundo [1]

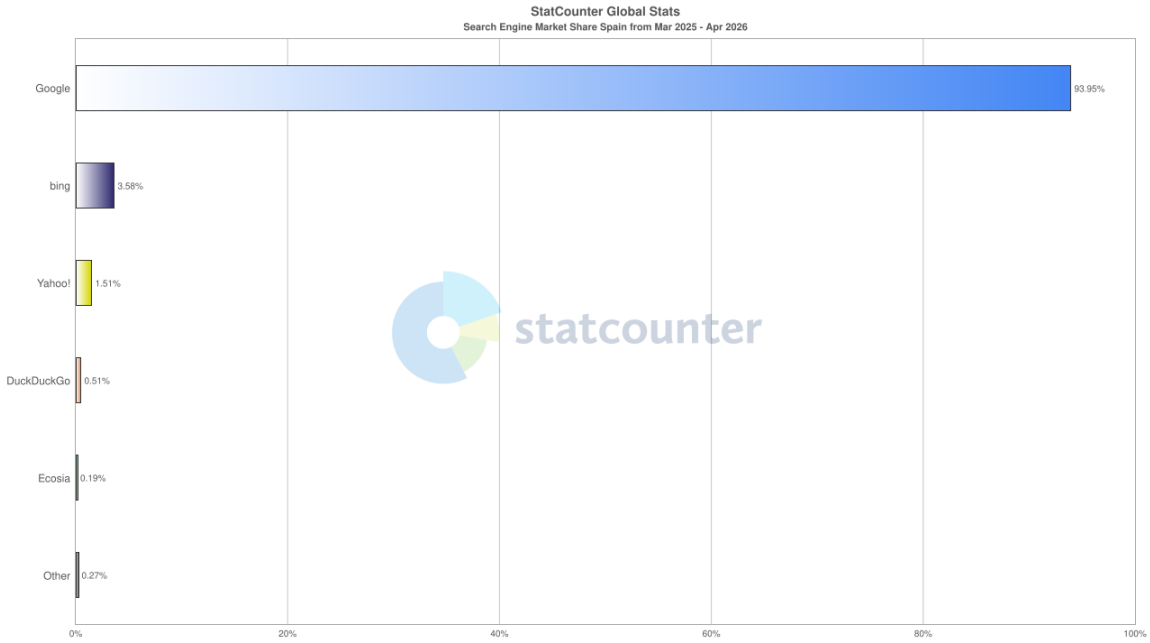


Figura 3.2: Cuota de mercado de los motores de búsqueda en el último año en España [1]

- **GPT:** Una de las razones principales de esta elección es la elevada cuota de mercado que tienen estos modelos en el ámbito de los LLM. En este caso, se ha utilizado el modelo GPT-4o mini, ya que permite tener un rendimiento adecuado, al tiempo que reduce significativamente los requisitos de recursos frente a modelos de mayor tamaño. Debido a los requisitos de obtención de URLs del estudio la dependencia del razonamiento profundo del modelo queda reducida. En este contexto, GPT-4o mini actúa como un compromiso óptimo entre eficiencia, disponibilidad mediante API y comportamiento suficientemente robusto. Dentro de este se utilizará tanto su versión con acceso a Internet desactivado (opera exclusivamente a partir de su conocimiento almacenado en sus parámetros durante el entrenamiento) como su versión con acceso a Internet activado (puede recuperar información web en tiempo real).

La unidad de análisis del estudio es la consulta individual. Para cada consulta del pool, se recogen los resultados proporcionados por los tres sistemas y se comparan a lo largo de tres dimensiones principales. Las URLs y dominios presentes en cada conjunto, el orden y la posición en la que aparecen los resultados y el grado de solapamiento de los mismos entre los sistemas.

El dominio de estudio se acota a consultas locales centradas en España, específicamente búsquedas de servicios como restaurantes, hoteles y otros establecimientos en ciudades españolas. Esto se debe a dos principales razones. Por un lado, las consultas locales constituyen uno de los casos de uso más frecuentes e inmediatos de los sistemas de búsqueda, con implicaciones

directas en la toma de decisiones de los usuarios. Por otro lado, estas consultas suelen ser muy sensibles al SEO local, así se podrá comprobar si los LLM también están influenciados o si tienen un funcionamiento y patrones de selección diferentes.

El diseño del estudio es de carácter observacional y no experimental: no se manipulan los sistemas evaluados ni se interviene en su funcionamiento, sino que se registran y analizan sus respuestas ante las mismas consultas en condiciones controladas.

3.2 Generación del pool de consultas

3.2.1 Consultas

La construcción de la base de datos de consultas es una de las claves del estudio, ya que la calidad y representatividad de las mismas afectan directamente a la validez de los resultados a obtener. El pool final está compuesto por 10.000 consultas en lengua española, todas ellas de carácter local y centradas en el mercado español. Se encuentran en el repositorio de Github [68].

El proceso de generación de consultas se dividió en dos fases. En la primera, se empleó el modelo de Perplexity AI para generar un borrador inicial de consultas organizadas por temáticas. Esta decisión responde a la necesidad de abordar de forma eficiente la creación de un volumen elevado de consultas, cuya elaboración manual resultaría inviable en términos de tiempo y esfuerzo. Las categorías cubiertas incluyen, entre otras, restaurantes, lugares de ocio, transporte y otros establecimientos de uso cotidiano, alcanzando en total las 15 categorías distintas. Las ciudades presentes en las consultas fueron determinadas por el propio proceso de generación del LLM, resultando en una selección variada de municipios españoles de distinto tamaño y distribución geográfica. No obstante, una revisión del borrador reveló severos problemas de formulación en las preguntas, estructuras gramaticalmente incorrectas, ausencia de verbos y determinantes, o formulaciones poco naturales que las hacían inadecuadas e inservibles a la hora de lanzarlas en los sistemas de búsqueda evaluados.

Para resolver este problema se diseñó una segunda fase de reformulación. Mediante un flujo de procesamiento por lotes (batching), se enviaron las consultas defectuosas a la API de OpenAI para su corrección y reformulación. Se instruyó al modelo para mantener el significado y la intención original, pero con una expresión natural y gramaticalmente correcta. Por ejemplo, se convirtieron consultas del tipo: 'Restaurantes asiáticos en Madrid' a '¿Cuáles son los mejores restaurantes de comida asiática en Madrid?'. Este enfoque de dos etapas permitió combinar la capacidad de los LLM para generar grandes volúmenes de consultas diversas con un control de calidad sistemático.

La distribución del conjunto de consultas no es homogénea entre categorías, presentando una

mayor concentración en el ámbito de la restauración. Esta decisión responde a criterios metodológicos, ya que las consultas relacionadas con restaurantes constituyen uno de los casos más representativos dentro de las búsquedas locales en España, tanto por su frecuencia como por ser el servicio más predominante en España.

Tabla 3.1: Distribución de consultas por categoría

Categoría	**Número de consultas**
Restaurantes	3819
Inmuebles	1025
Comercios	796
Belleza y Estética	630
Deporte y Fitness	549
Cafeterías y Bares	422
Servicios Médicos	394
Reparaciones	378
Ocio y Entretenimiento	346
Alojamiento	328
Mascotas	285
Servicios Profesionales	273
Educación	264
Transporte	259
Eventos	232

3.2.2 Subconjunto de análisis

De forma complementaria al pool principal, se generó un subconjunto adicional de 200 consultas correspondientes a búsquedas de alta popularidad en España. Este subconjunto recoge consultas ampliamente reconocidas y de uso frecuente entre los usuarios españoles. El objetivo de este subconjunto es focalizar el análisis para las que cabe esperar una mayor coincidencia entre los sistemas evaluados, dado que se trata de entidades bien representadas tanto en los índices de los motores de búsqueda como en los corpus de entrenamiento de los LLM. Asimismo, facilita la identificación de patrones específicos asociados a la popularidad de las consultas, complementando así los resultados obtenidos sobre el pool general.

En cuanto a la distribución de este segundo conjunto de consultas, estas se organizan en 15 categorías, destacando las relativas a restauración y turismo, que superan las 20 consultas cada una. Esta mayor representación responde a la relevancia estructural de ambos sectores en el contexto español, tanto por su peso económico como por su elevada presencia en las búsquedas de carácter local.

Estas preguntas son del estilo de: '¿Cuáles son los actores más famosos de España?' o '¿Dónde

están los puertos más importantes de España?'.

Tabla 3.2: Distribución de consultas populares por categoría

Categoría	Número de consultas
Restaurantes y Gastronomía	21
Turismo y Monumentos	21
Ocio y Entretenimiento	18
Moda y Ropa	15
Deporte y Fitness	13
Educación	13
Alojamiento y Hoteles	13
Supermercados y Alimentación	12
Salud y Medicina	12
Transporte y Movilidad	12
Bancos y Finanzas	11
Tecnología y Telecomunicaciones	11
Servicios Profesionales	11
Inmuebles	10
Mascotas	8

3.3 Herramientas y APIs utilizadas

La obtención de resultados de los tres sistemas evaluados se realizó de forma completamente automatizada mediante el uso de dos APIs externas: DataForSEO [69] para la obtención de resultados de Google Search y la API de OpenAI para la obtención de respuestas de GPT-4o mini en sus dos modalidades. A continuación se describe el funcionamiento y configuración de cada una de ellas.

3.3.1 DataForSEO

Es una API especializada en la obtención de datos de motores de búsqueda que permite realizar consultas programáticas a Google Search y recuperar sus resultados en formato estructurado JSON, sin necesidad de scraping directo y con plenas garantías de estabilidad y escalabilidad.

En fases preliminares se exploró el uso de herramientas y APIs gratuitas, como OpenSERP, para la obtención de resultados. Sin embargo, debido al elevado volumen de consultas, estas soluciones presentaron limitaciones operativas, derivando en bloqueos automáticos asociados a mecanismos de seguridad y detección de tráfico automatizado. Se descartó su uso al no

garantizar la estabilidad ni la continuidad necesarias para la ejecución del experimento a gran escala.

Para cada una de las consultas se realizó una petición a la API configurada para recuperar los diez primeros resultados orgánicos de Google Search, excluyendo anuncios o resultados de Google Maps que podían distorsionar la comparativa. De cada resultado se extrajeron tres campos, información mínima para el análisis: el rango o posición en el SERP (Siglas en inglés que significan: Página de Resultados del Motor de Búsqueda), el título de la página y la URL completa.

3.3.2 API de OpenAI

La API de OpenAI se utilizó para obtener las respuestas de GPT-4o mini en dos condiciones experimentales distintas, la primera de ellas sin activar la búsqueda web, obligando al modelo a responder de su conocimiento de entrenamiento, y la segunda activando la opción a través de las `tools` al hacer la llamada a la API localizando al usuario en España.

```
tools=[
    {
        "type": "web_search",
        "user_location": {
            "type": "approximate",
            "country": "ES",
            "region": "España",
            "city": "España"
        },
        "search_context_size": "medium"
    }
],
include=["web_search_call.action.sources"]
```

En ambas condiciones el prompt enviado al modelo fue cada una de las consultas del pool, instruyendo al modelo a responder con un formato específico a través del atributo `text_format`. Dicho formato consistía en una lista estructurada de enlaces, donde cada elemento incluía el nombre de la página web y su correspondiente URL.

3.4 Obtención y procesamiento de respuestas

Una vez definidas las consultas y configuradas las API, se procedió a la obtención sistemática de resultados para cada uno de los tres sistemas evaluados. El proceso se diseñó de forma

secuencial, cada consulta fue lanzada de forma individual y consecutiva a cada uno de los sistemas, esperando la respuesta completa antes de proceder con la siguiente petición. De esta manera se garantizaba la estabilidad del proceso y el tratamiento de errores. Para poder lanzar el proceso se desarrollaron tres scripts de Python (lenguaje de programación), uno por cada sistema. En total teniendo en cuenta que para cada consulta se debían de realizar tres llamadas distintas y a que se replicó este proceso íntegramente para el subconjunto de 200 consultas se llevaron a cabo 30.600 peticiones a las APIs a lo largo de todo el experimento.

El almacenamiento de los resultados siguió formatos diferenciados según el sistema. En el caso de Google Search, a través de DataForSEO, las respuestas se obtuvieron en formato JSON. Si bien la API proporcionaba un objeto extenso que incluía la totalidad del SERP (como anuncios, búsquedas relacionadas, imágenes o resultados de Google Maps), en este estudio se llevó a cabo un proceso de filtrado para conservar únicamente las diez primeras páginas web orgánicas. De cada resultado se almacenaron exclusivamente los atributos definidos previamente: posición en el ranking, título y URL.

Los resultados generados por GPT-4o mini en sus dos condiciones experimentales se almacenaron como columnas adicionales en el mismo fichero Excel que contenía el pool de consultas, de forma que cada fila recogía la consulta original y su categoría junto con las respuestas del modelo con y sin acceso a Internet. Posteriormente, se añadió una tercera columna de respuestas al mismo archivo, utilizando la información extraída del archivo JSON resultante del filtrado de respuestas obtenido a través de la API de Google. Como resultado, se obtuvo un archivo Excel consolidado que integra todas las consultas y sus respectivas respuestas, listo para su análisis.

Cabe destacar que el número de resultados devueltos por GPT-4o mini era variable.

Durante el proceso de obtención de resultados se identificaron casos en los que alguno de los sistemas no devolvió resultados válidos para una consulta determinada. Estas situaciones se produjeron por diversas causas: errores puntuales en la comunicación con las APIs, consultas repetidas o respuestas malformadas del modelo. Todos estos casos fueron registrados y tratados como excepciones para no forzar el detenimiento del proceso de obtención de resultados.

Finalmente, con el objetivo de garantizar un análisis de resultados lo más homogéneo posible, y considerando la heterogeneidad en el formato de las respuestas, se llevó a cabo un proceso de normalización de los datos. En concreto, se unificó el formato de las URL obtenidas en los tres sistemas de búsqueda, para permitir su comparación directa. Asimismo, se extrajeron los dominios asociados a cada una de las URL, con el fin de realizar un análisis adicional basado en dominios.

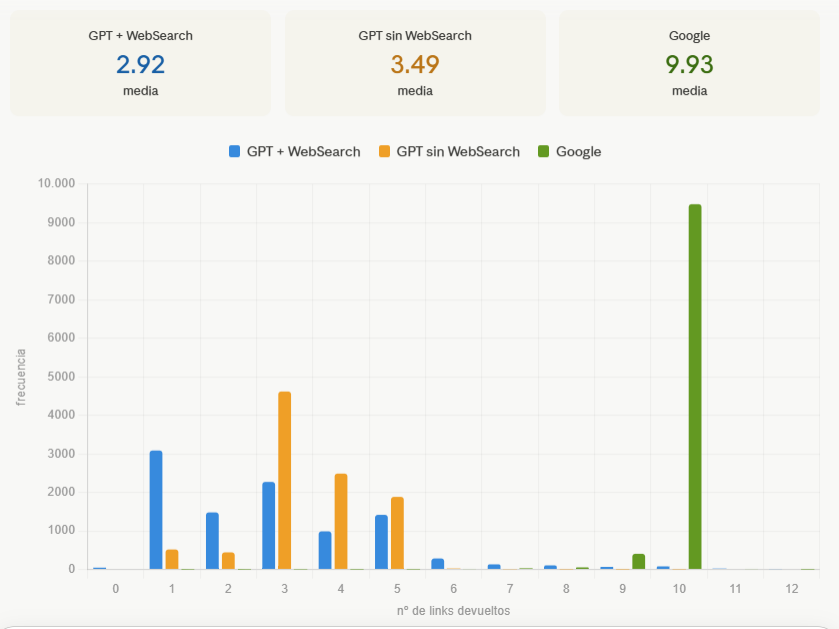


Figura 3.3: Número de enlaces por consulta

3.5 Herramienta web comparativa

Como parte del estudio también se ha desarrollado una herramienta para web denominada SearchLab que permite realizar comparativas en tiempo real entre los tres sistemas de recuperación de información evaluados en el estudio. La herramienta ofrece dos modos de uso: en el primero el usuario introduce una consulta en lenguaje natural y visualiza las distintas respuestas de los tres sistemas y las comparativas de los mismos (por ejemplo si coincide alguna URL), en el segundo el usuario introduce una consulta y la dirección web que desee para comprobar si aparece en alguno de los tres sistemas y en que posición. La aplicación se ha desarrollado con una arquitectura cliente-servidor desacoplada, con un frontend web independiente y un backend en Python que actúa como intermediario entre la interfaz y las APIs externas.

3.5.1 Backend

El backend está desarrollado en Python utilizando el framework de Flask, una biblioteca ligera orientada al desarrollo de APIs web y aplicaciones de servidor. La aplicación se estructura en torno a dos endpoints principales expuestos bajo el prefijo `/api`.

El primer endpoint, `/api/search` recibe una consulta en lenguaje natural mediante una petición POST y devuelve un objeto JSON con los resultados de cada fuente (tras hacer una

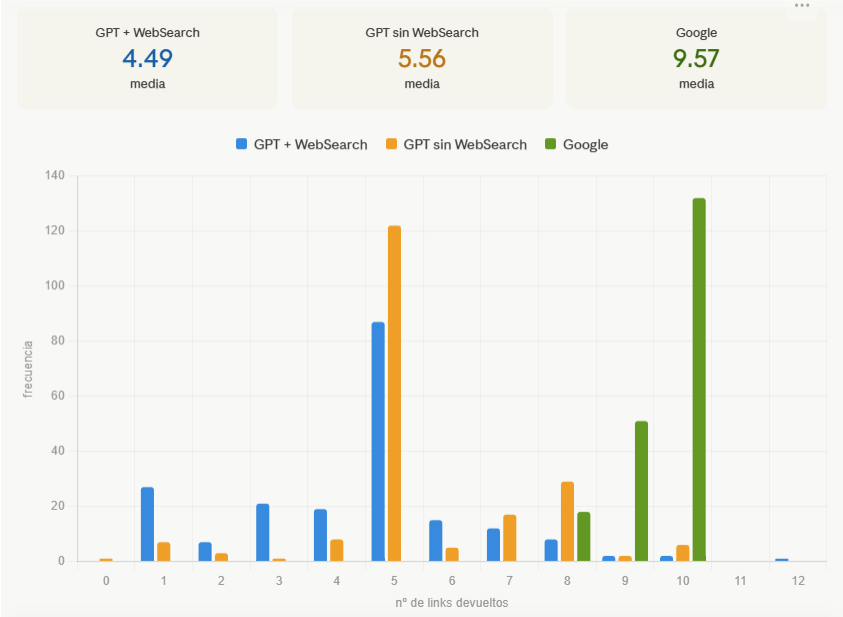


Figura 3.4: Número de enlaces por consulta (preguntas populares)

llamada a la API de cada fuente), un ranking global combinado y un conjunto de métricas de análisis de coincidencias.

El segundo endpoint, `/api/url-report`, responde al segundo modo de uso de la herramienta web. Recibiendo una consulta y una URL devuelve la posición exacta en la que dicha URL aparece, si esta presente, en las respuestas de cada uno de los tres sistemas.

El análisis comparativo se implementa mediante dos funciones adicionales. Primero, se normalizan todas las URL obtenidas. Seguidamente a cada URL se le asigna una puntuación basada en la posición dentro de las respuestas de cada sistema, si está en la posición 1 recibe 10 puntos, si está en la 2 recibe 9 y así sucesivamente. Las puntuaciones se acumulan entre fuentes, generando un ranking global que refleja tanto la relevancia asignada por cada sistema como el grado de consenso entre ellos. Adicionalmente se calculan métricas de solapamiento entre pares, para así poder comprobar las coincidencias entre sistemas.

3.5.2 Frontend

El frontend se ha desarrollado como SPA (single page app) en HTML5, CSS3 y JavaScript vanilla. La interfaz se sirve directamente desde el servidor Flask mediante la ruta raíz `/`. Cada sistema de recuperación tiene asignado un color identificativo que se mantiene a lo largo de toda la interfaz: naranja para Google, azul para GPT con búsqueda y verde para GPT sin búsqueda.

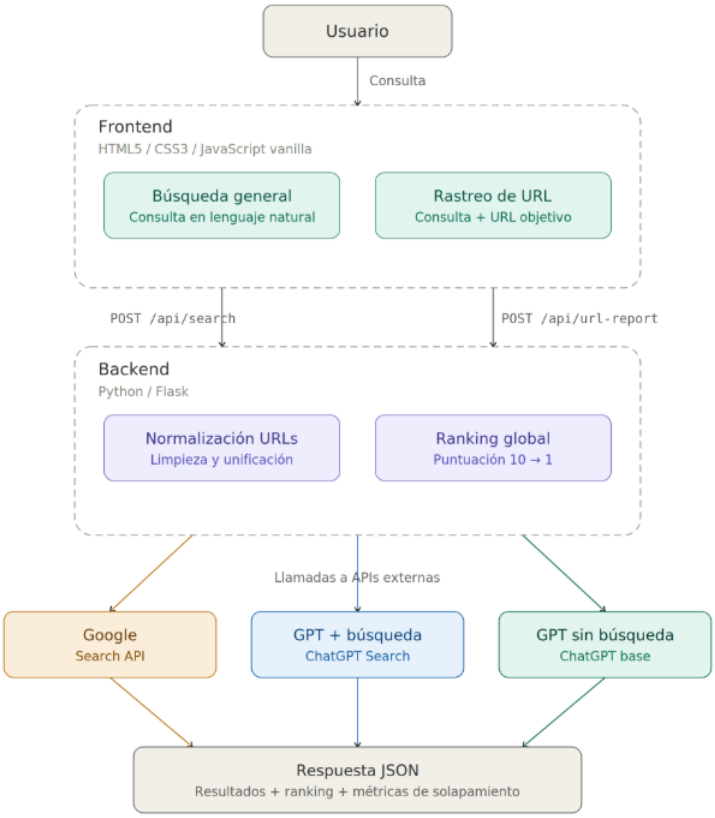


Figura 3.5: Arquitectura de SearchLab

La interfaz se organiza en dos secciones principales accesibles desde la misma página. La primera sección corresponde al modo de búsqueda general. Dicha interfaz se divide en tres bloques: un panel de análisis de coincidencias, un ranking global combinado con la puntuación acumulada de cada URL y una vista de tres columnas en paralelo que muestra los resultados de cada sistema ordenados por posición, con título y URL de cada resultado.

La segunda sección corresponde al modo de rastreo de URL. Al rastrear una dirección web muestra de forma destacada la posición (o asuencia) de la URL objetivo en cada uno de los tres sistemas, y presenta además los resultados completos de cada fuente con la URL objetivo resaltada visualmente.

La comunicación entre frontend y backend se realiza íntegramente mediante peticiones asíncronas en formato JSON, con gestión de errores mediante un componente de alerta visible que informa al usuario en caso de fallo en las APIs externas o de consulta vacía.

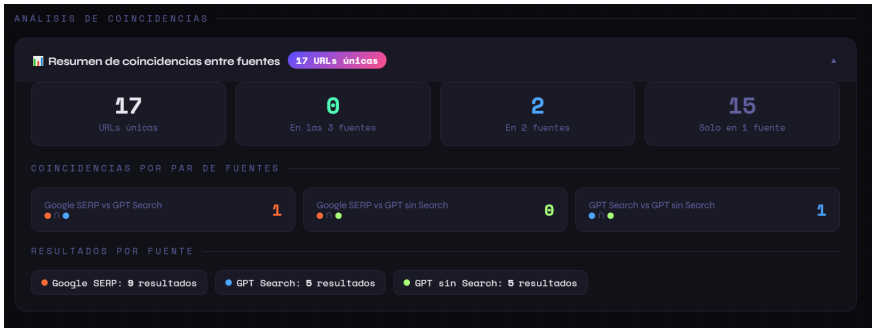


Figura 3.6: Interfaz1 de modo de búsqueda general

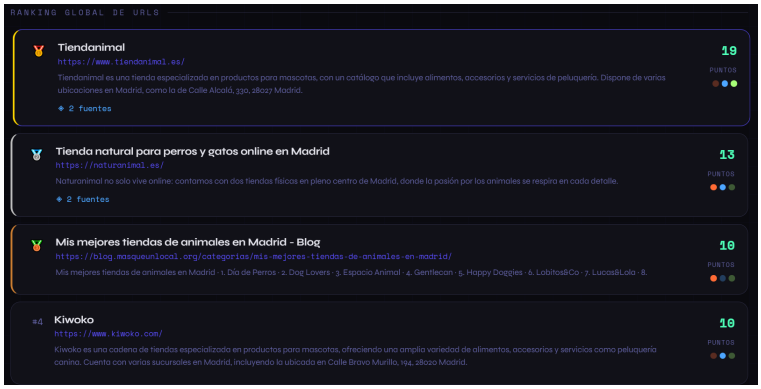


Figura 3.7: Interfaz2 de modo de búsqueda general



Figura 3.8: Interfaz de modo de búsqueda de rastreo

Resultados

4.1 Análisis del pool de 10.000 consultas locales

4.1.1 Introducción al análisis comparativo

Se presenta un análisis de las diferencias estructurales entre los tres sistemas evaluados: Google, GPT con Search y GPT sin Search. El objetivo es caracterizar cuantitativamente el grado de divergencia en los resultados obtenidos ante las 10000 consultas del dataset y comprender los patrones que subyacen a estas diferencias.

El análisis se estructura en cinco dimensiones complementarias. En primer lugar, se cuantifica la similitud global mediante métricas de solapamiento de URLs y dominios, estableciendo una línea base sobre el grado de coincidencia entre pares de sistemas. A continuación, se desagrega este análisis por categoría temática, identificando en qué tipos de servicio la divergencia es más pronunciada y en cuáles existe mayor consenso. El tercer eje examina el universo de dominios empleado por cada sistema y los dominios más frecuentes, caracterizando los perfiles informacionales predominantes. En cuarto lugar, se analizan los dominios exclusivos de cada fuente, revelando las lógicas de priorización específicas de cada sistema. Finalmente, se presentan casos frontera de alta y baja coincidencia, ilustrando mediante ejemplos concretos los patrones observados en las métricas agregadas.

4.1.2 Similitud global entre sistemas

El primer eje de análisis consiste en cuantificar el grado de solapamiento entre los resultados obtenidos antes las 10000 consultas, para ello la comparación se hace por pares de sistema. Se emplearan cuatro métricas complementarias.

El índice de Jaccard sobre URLs exactas normalizadas, este índice mide la intersección (elementos comunes) dividida por la unión (elementos totales únicos) de los conjuntos. Representando A y B los conjuntos de URLs devueltas por cada sistema.

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \tag{4.1}$$

El porcentaje de consultas sin ninguna coincidencia de URL y sin ninguna coincidencia por dominio.

$$P_{\text{sin coincid.}} = \frac{\text{número de consultas con } |A \cap B| = 0}{\text{total de consultas}} \times 100 \tag{4.2}$$

Y la similitud sesgada de dominio y de URL, mide qué fracción de los dominios/URLs del sistema A aparecen también en el sistema B; esto se debe principalmente a la diferencia en el número de enlaces recibido por GPT y por Google. De esta manera se medirá que porcentaje de dominios del sistema con menos enlaces se representan en el que tiene más enlaces.

$$S_{\text{sesgada}}(A \to B) = \frac{|A \cap B|}{|A|} \tag{4.3}$$

Los resultados revelan un solapamiento extraordinariamente bajo en los tres pares analizados, tal y como se recoge en la Tabla 4.1. El par con mayor similitud es GPT+Search vs Google, con un índice de Jaccard medio de apenas 0,0322, lo que implica que en promedio solo el 3,2 % de las URLs son compartidas entre ambos sistemas. El 69,6 % de las consultas no presentan ninguna URL en común entre GPT con búsqueda y Google. La situación es aún más extrema para los otros dos pares: GPT sin Search vs Google obtiene un Jaccard de apenas 0,0023, con un 97,4 % de consultas sin ninguna coincidencia. GPT+Search vs GPT sin Search alcanza un Jaccard de 0,0054, con un 97,9 % de consultas sin URLs compartidas. Este último resultado es especialmente llamativo, evidenciando el impacto del acceso a Internet en la obtención de resultados. Como se puede observar las métricas siguen un patrón similar, los pares más parecidos, o ente caso menos distantes son GPT con Search y Google.

Par	**Jaccard URL (media)**	**% sin coincid. URL**	**Sesgada URL (media)**	**Sesgada Dom. (media)**	**% sin coincid. Dom.**
GPT con Search vs Google	0,0322	69,6	0,1436	0,3426	43,8
GPT sin Search vs Google	0,0023	97,4	0,0077	0,1548	69,1
GPT con Search vs GPT sin Search	0,0054	97,9	0,0113	0,0795	86,6

Tabla 4.1: Comparación de métricas entre sistemas

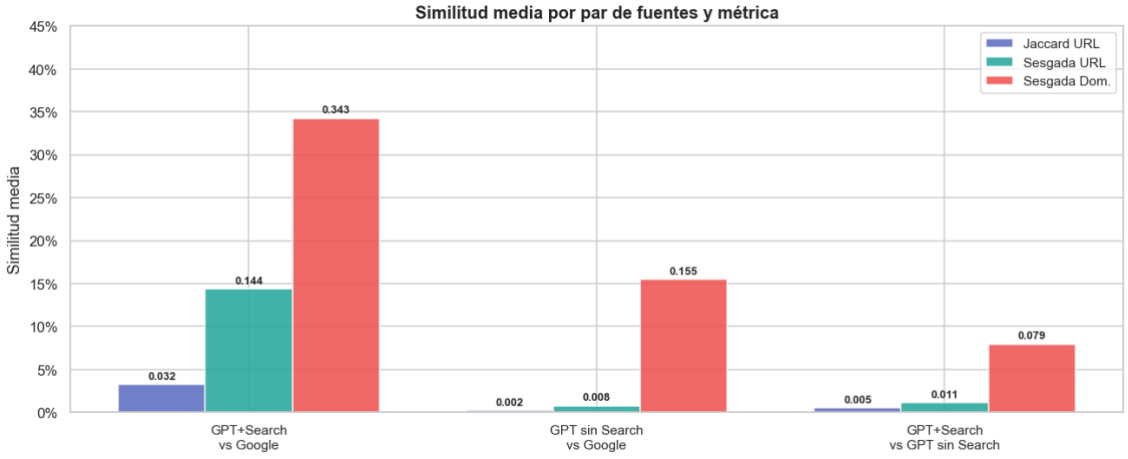


Figura 4.1: Gráfico comparativo de métricas entre sistemas

4.1.3 Análisis por categoría temática

El análisis desagregado por categoría temática revela que el solapamiento entre sistemas no es homogéneo, sino que varía considerablemente en función del tipo de servicio consultado. Las categorías con mayor similitud de dominio son aquellas donde existen plataformas conocidas y dominantes. Como pueden ser *idealista.com* o *fotocasa.es* en Inmuebles o *renfe.com* y *aena.es* en Transporte. En el extremo opuesto, las categorías con menor solapamiento coincidan con mayor atomización del mercado y mayor influencia del SEO local, como Restaurantes o Servicios Profesionales. En estos casos Google tiende a recomendar directorios y agregadores de reseñas mientras que GPT webs de establecimientos individuales.

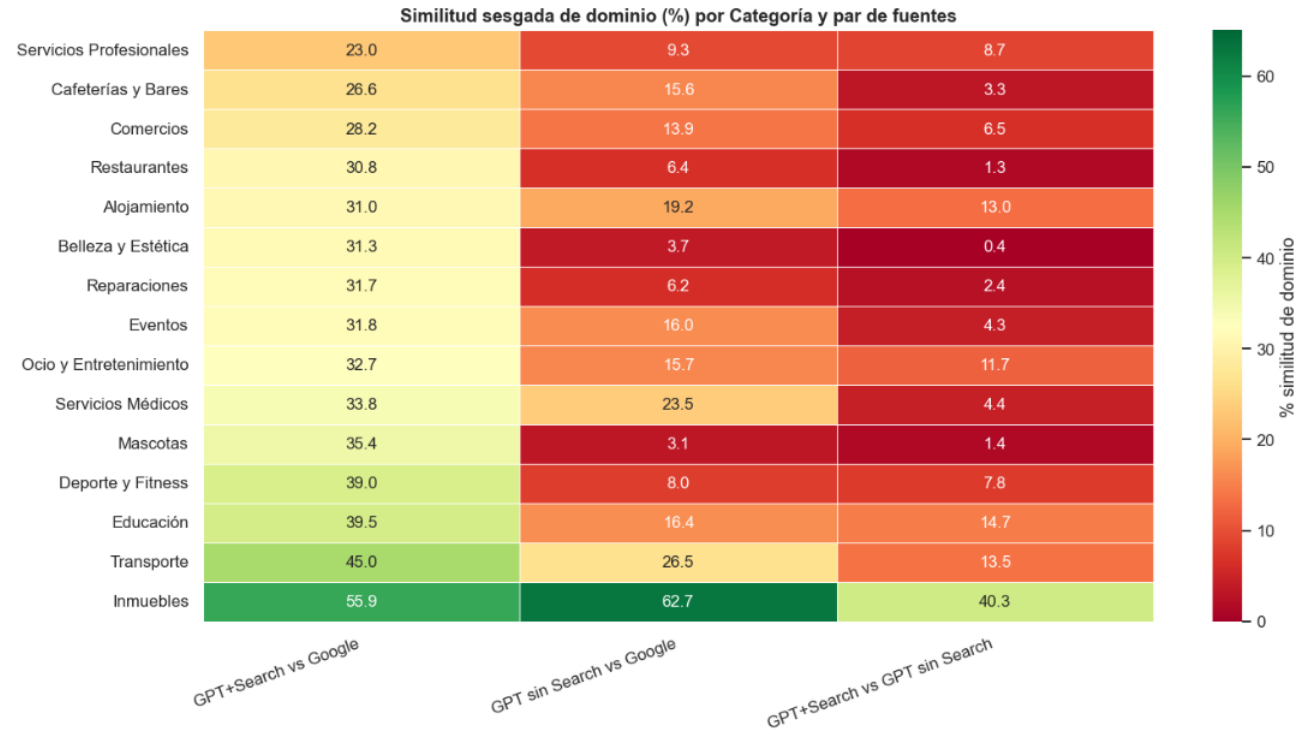


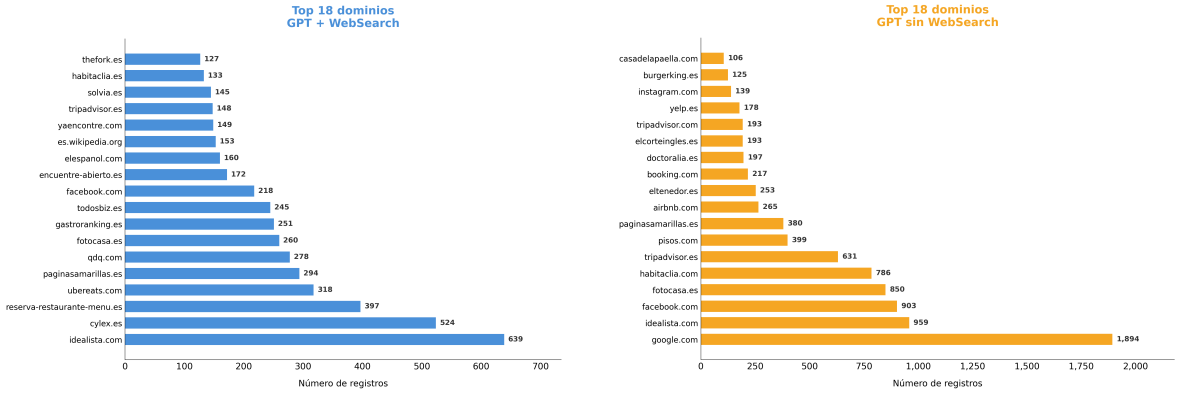
Figura 4.2: Heatmap que mide la similitud sesgada de dominio por categoría

4.1.4 Universo de dominios y top dominios por fuente

El siguiente paso en el análisis es examinar el universo de dominios empleado por cada uno de los tres sistemas. GPT con Search utilizó un total de 12508 dominios únicos en las 10000 respuestas, su versión sin search alcanzó los 13088 y Google alcanzó aproximadamentre los 20000 superando al LLM. Este desenlace se presenta de una forma contraintuitiva, cabría esperar que GPT con Search aportara un universo de dominios más rico y variado, sin embargo,

en realidad al desactivar esa opción aumentan los dominios, aunque probablemente algunos esten desactualizados y no sean funcionales.

El análisis de los dominios más frecuentes por fuente, representado en la Figura 4.3, pone de manifiesto perfiles cualitativamente distintos entre los tres sistemas. Google, por su parte, prioriza directorios de reseñas y contenido editorial, como tripadvisor, timeout, youtube o reddit. Los dos GPT comparten un perfil más enciclopédico y generalista, con es.wikipedia.org como dominio más recurrente en ambos casos, seguido de portales oficiales y webs corporativas de grandes marcas.



(a) GPT con Search **(b)** GPT sin Search

Figura 4.3: Dominios más representados por GPT

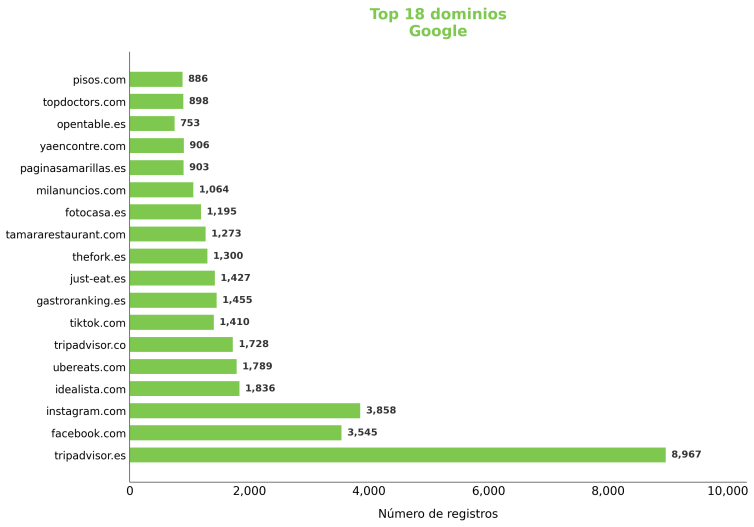
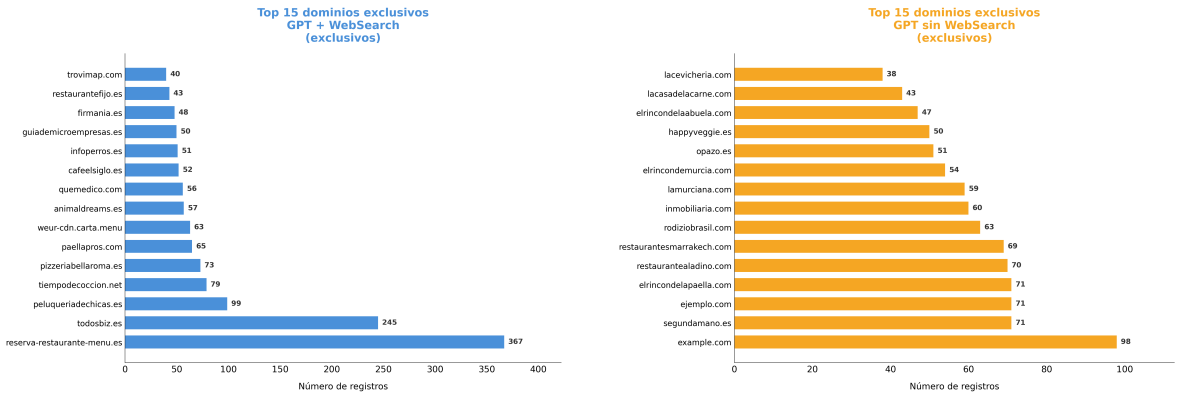


Figura 4.4: Dominios más representados por Google

4.1.5 Dominios exclusivos de cada fuente

Para profundizar en las diferencias presentadas entre los tres sistemas, se analizaron los dominios que aparecen exclusivamente en una de las tres fuentes. Este análisis permite caracterizar el perfil informacional propio de cada sistema más allá de las métricas de solapamiento.

Los dominios exclusivos de Google corresponden en su mayoría a plataformas de reseñas locales, directorios de negocios, medios de comunicación regionales y redes sociales reflejando la lógica del ranking por popularidad y autoridad de enlace propia del algoritmo PageRank. Si se pone el foco sobre GPT con Search aparecen portales oficales de instituciones, web gubernamentales y páginas corportaivas de grandes marcas, sugiriendo que tiende a priorizar fuentes de alta autoridad percibida. Por último GPT sin Search presenta un perfil más estático, webs de grandes cadenas comerciales, portales de referencia nacionales y dominios que pueden no reflejar el estado actual del mercado; además aparece el dominio example.com, un dominio reservado para ejemplos, marcadores de posición o documentación, no para fuentes reales; indicando la ausencia de URL reales y válidas.



(a) GPT con Search **(b)** GPT sin Search

Figura 4.5: Dominios exclusivos de GPT

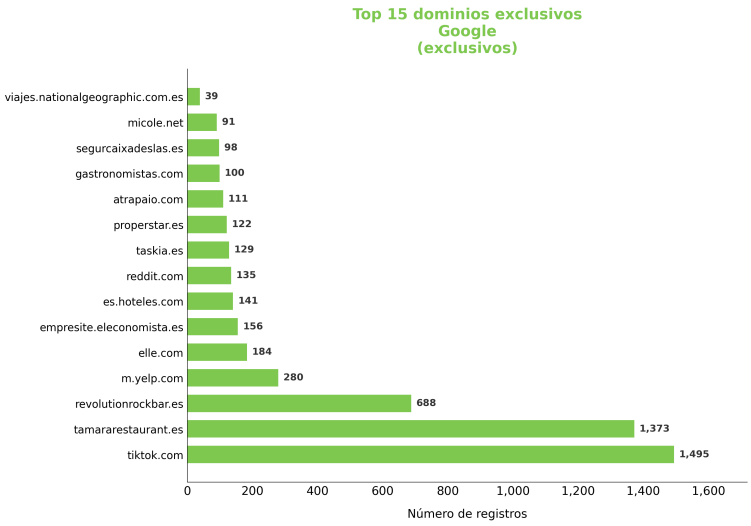


Figura 4.6: Dominios exclusivos de Google

4.1.6 Casos frontera: alta y baja coincidencia

Para complementar y enriquecer el análisis, se identificaron ejemplos de coincidencia máxima y mínima entre sistemas.

Por ejemplo, entre las consultas con mayor coincidencia entre GPT con Search y Google destacan consultas del tipo '¿Cuáles son los mejores restaurantes de sushi en Alicante?' o 'Gimnasios en L'Hospitalet de Llobrega', búsquedas para las que existe un conjunto reducido de establecimientos bien posicionados en los dos sistemas, sugiriendo que los resultados más relevantes son suficientemente prominentes.

Entre las consultas con ninguna coincidencia entre GPT con Search y Google se encuentran búsquedas como 'Peritos en Zaragoza', 'Cocina De Autor en Madrid' o 'Panaderías en Burgos', categoirías con un mercado local muy fragmentado y fuerte influencia del SEO en el posicionamiento de Google. Google tiende a devolver listas de establecimientos, mientras que GPT genera webs de establecimientos individuales.Esta divergencia es especialmente pronunciada entre GPT sin Search y Google, donde el 97,4 % de las consultas no presenta ninguna URL en común, confirmando la insuficiencia del conocimiento paramétrico del modelo para replicar los resultados de búsqueda local en la gran mayoría de casos.

4.2 Análisis del subconjunto de 200 consultas populares

El segundo gran bloque de esta exploración se centra en el subconjunto de 200 consultas de alta popularidad, para el que cabe esperar un mayor grado de consenso entre los sistemas, al tratarse de entidades y servicios ampliamente representados en los índices de los motores de búsqueda como en el corpus de entrenamiento de los LLM. Además, permiten contrastar si los patrones observados en el análisis previo se mantienen o varían. A parte, para este segundo análisis se enfatiza más en las URLs compartidas, no tanto en los dominios.

4.2.1 Similitud global y comparativa con las 10.000 consultas

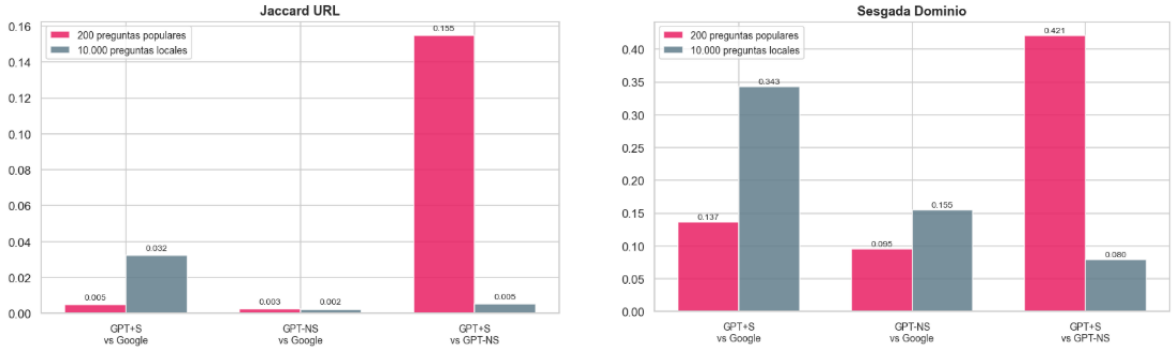
Además de diferencias cuantitativas relevantes el análisis de similitud de este segundo subconjunto muestra un patrón general distinto del primero. Ahora GPT con Search y GPT sin search es el par que presenta el mayor solapamaiento, aunque en términos absolutos el porcentaje sigue siendo bajo, confirmando que la divergencia estructural se mantiene.

Si se utilizan las métricas anteriores (Tabla 4.2) se puede observar como en el par con mayor solapamiento se alcanzan valores de hasta el 0,15 en el Jaccard de las URL cuando el máximo en el anterior conjunto era de 0,0322.

Comparación	**Jaccard URL (media)**	**% sin coincid. URL**	**Sesgada Dom. (media)**	**% sin coincid. Dom.**
GPT con Search vs Google	0,004700	94,500000	0,136700	75,600000
GPT sin Search vs Google	0,002600	97,000000	0,095400	80,100000
GPT con Search vs GPT sin Search	0,154800	50,700000	0,420900	30,800000

Tabla 4.2: Métricas de similitud y coincidencia entre sistemas

Comparando estos valores con los del análisis previo se observa que a pesar de que GPT sin Search y GPT con Search han aumentado considerablemente su parecido en las respuestas, el par de GPT con Search y Google ha bajado drásticamente en todas las métricas. Este resultado resulta inesperado y sorprendente, dado que, en preguntas de carácter más generalista, como '¿Cuáles son los influencers más famosos de España?', cabría anticipar una mejora en las métricas obtenidas por una mayor convergencia de los sistemas.



(a) Métrica Jaccard **(b)** Similitud sesgada por dominios

Figura 4.7: Gráficas comparativas entre métricas de similitud

Al hacer énfasis sobre el número de dominios y URL compartidos se ve como el número de coincidencias de Google con los GPT también cae drásticamente, esto se debe a que el dominio de wikipedia se cita abundantemente, pero dentro de wikipedia existen muchos artículos de los cuales no existen muchas coincidencias entre sistemas.

Par	**Coincidencias por dominio**	**Coincidencias por URL**
GPT con Search vs GPT sin Search	310	310 (más preciso)
GPT con Search vs Google	66	14
GPT sin Search vs Google	40	13

Tabla 4.3: Coinicidencias por dominio y por URL

Cabe añadir que existen 5 URL que han sido referenciadas por los tres sistemas de búsqueda en la misma consulta. Estas son, con las posiciones en las que han sido referenciadas:

Enlace	**Google**	**GPT con Search**	**GPT sin Search**
`https://www.topdoctors.es/`	1	1	1
`https://www.elisava.net/`	4	1	3
`https://www.doctoralia.es/`	3	2	2
`https://www.apple.com/es/retail/puertadelsol/`	4	1	1
`https://www.tusclasesparticulares.com/`	6	2	2
`https://www.museodelbaileflamenco.com/`	6	5	5
`https://www.avis.es/`	9	5	4

Tabla 4.4: URLs coincidentes entre Google, GPT con Search y GPT sin Search

4.2.2 Análisis por categoría temática

El análisis desagregado por categoría en el subconjunto de 200 consultas populares muestra una mayor similitud en categorías como Transporte y Movilidad, donde sorprende la igualdad entre los tres pares. La categoría de Turismo y Monumentos por su parte, muestra una similitud entre los dos GPT altísima alcanzando casi el 70 %, contrastando con la baja similitud respecto de Google, situación que se repite en menor medida en otras categorías como Moda y Ropa, Tecnología y Comunicaciones o Deporte y Fitness.

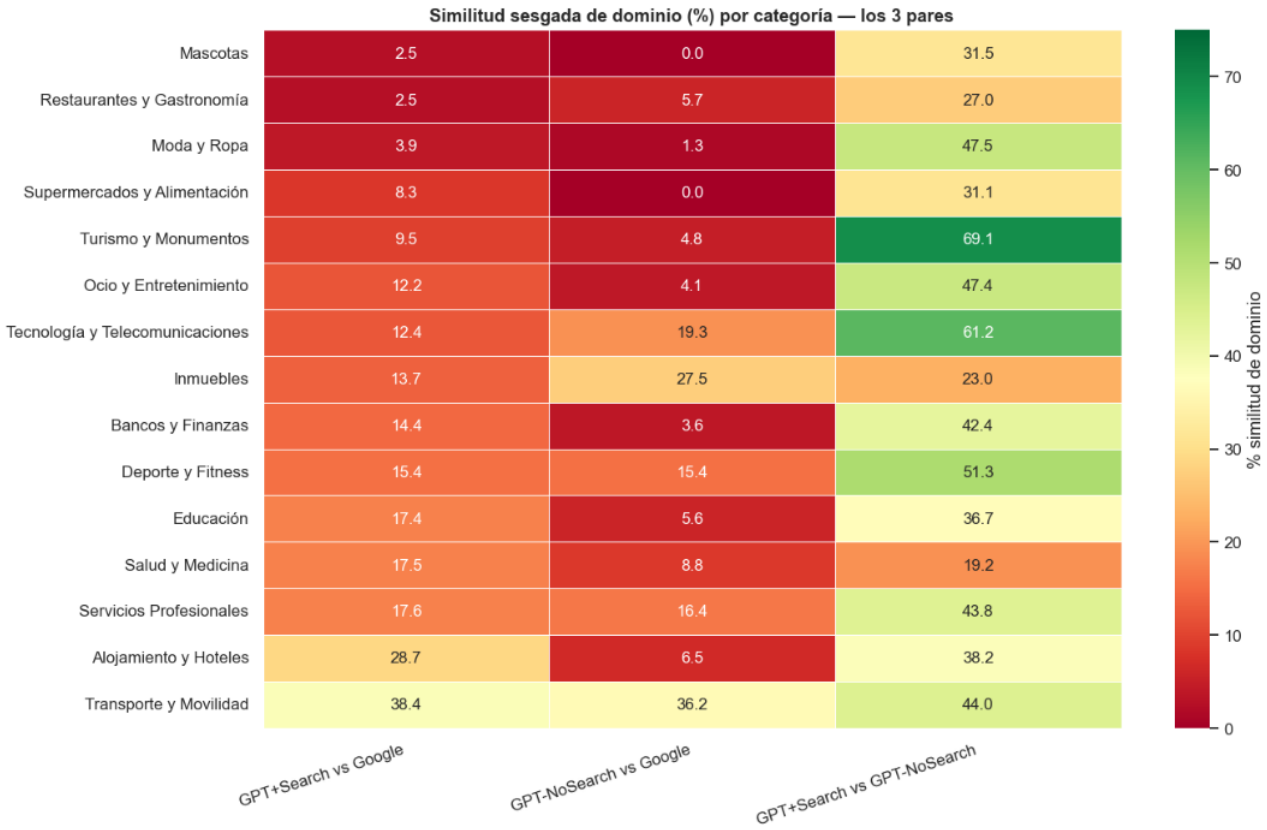


Figura 4.8: Heatmap que mide la similitud sesgada de dominio por categoría

4.2.3 Top dominios por fuente

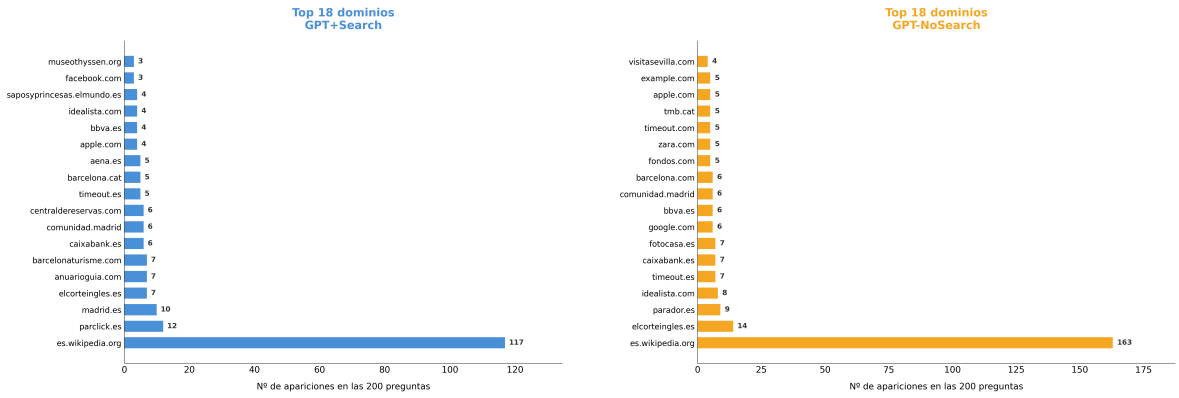
Para este subconjunto también se lleva a cabo una exploración de los dominios más representados. Google referencia en total 1923 dominios independientes, GPT con Search 903 y GPT sin Search 1117, siguiendo la distribución observada en los resultados de las 10000 consultas. En los dos GPT destaca con mucha diferencia sobre el resto *www.wikipedia.org*, exhibiendo una tendencia enciclopédica, cabe recalcar que el porcentaje de preguntas en las que aparece

este dominio es incluso menor que el pocentaje que tiene sobre la cantidad de dominios total. Esto denota un desbalanceo importante en la aparición del dominio, mostrando que cada vez que se cita el dominio se hace consecutivamente. En otras palabras habrá preguntas con 6 menciones a wikipedia y otras con 0.

Estas conclusiones indican que se trata de un sesgo inherente al conocimiento paramétrico del modelo en ciertas categorías y no un efecto del acceso a Internet. Estas categorías donde se agolpaban las menciones de wikipedia eran Turismo y Monumentos (más del 50 % de apariciones por cada GPT) y Transporte y Movilidad (20-30 % de apariciones). En otras categorías como Gastronomía, Salud, Educación, Alojamiento, Mascotas, Servicios Profesionales y Tecnología ni aparece; un 47 % de las categorías.

Motor	**Preguntas con Wikipedia**	**% sobre el total de dominios**
GPT con Search	23 de 200 (11,4 %)	117 de 903 (13,0 %)
GPT sin Search	22 de 200 (10,9 %)	163 de 1117 (14,6 %)
Google	12 de 200 (6,0 %)	13 de 1923 (0,7 %)

Tabla 4.5: Presencia de Wikipedia en los resultados de cada motor



(a) GPT con Search **(b)** GPT sin Search

Figura 4.9: Dominios más representados por GPT

Respecto a Google se vuelve a apreciar como tiende a referenciar directorios o agregadores de reseñas como tripadvisor, timeout, youtube o reddit; casualmente el mismo top que se presenciaba en las 10000 consultas.

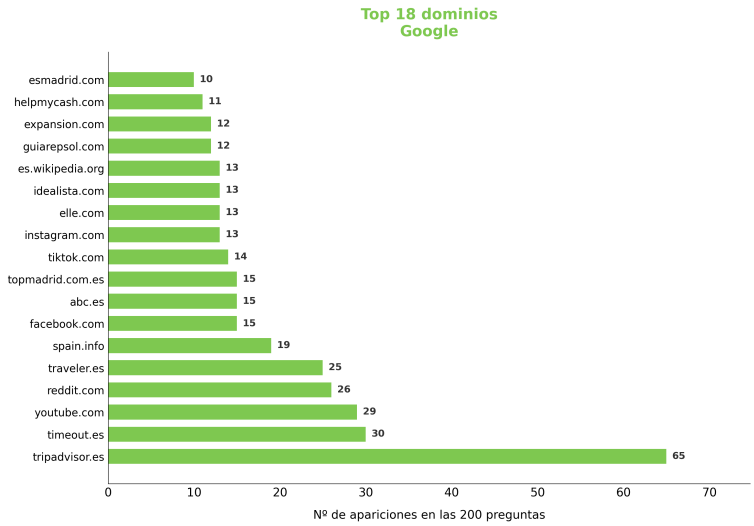


Figura 4.10: Dominios más representados por Google

4.2.4 Análisis de posiciones y orden de resultados

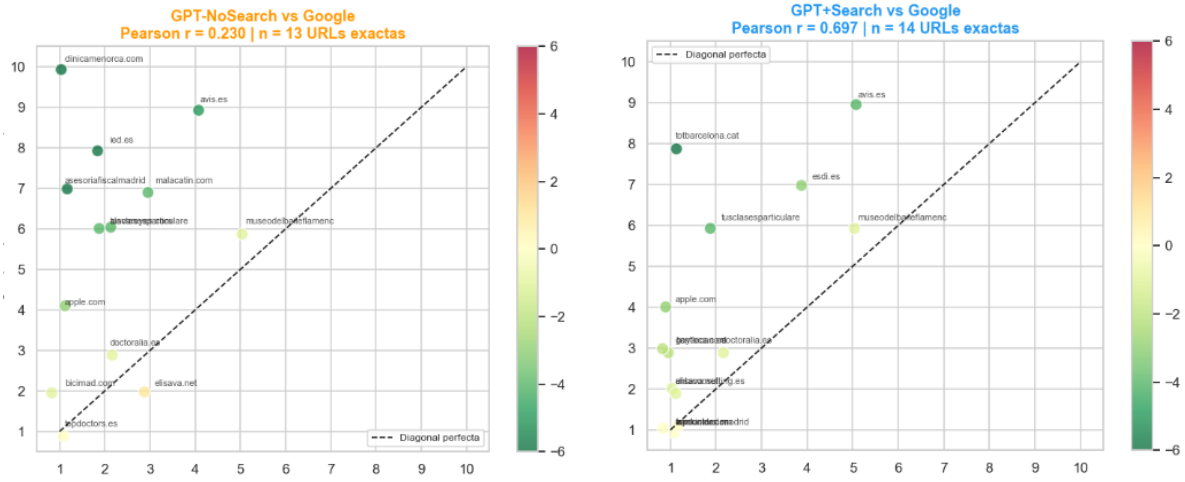
Para profundizar en el análisis de las URL de este subconjunto, el análisis de posiciones aborda una dimensión adicional, cuando 2 sistemas coinciden en citar la misma URL ¿lo hacen en el mismo orden? Esta pregunta es relevante porque el orden de los resultados refleja la priorización implícita de cada sistema y tiene un impacto directo en el comportamiento del usuario.

Para ello, haremos uso del coeficiente de correlación de Pearson (r), que mide la fuerza y dirección de la relación lineal entre dos variables cuantitativas (en este caso el ranking de las webs coincidentes). Este coeficiente puede tomar un valor entre -1 y 1, siendo 1 la correlación postiva perfecta y 0 la ausencia de correlación. Representando x_i e y_i las posiciones de la URL i en los sistemas A y B respectivamente, $\bar{x}$ e $\bar{y}$ las posiciones medias, y n el número de URLs coincidentes:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}} \tag{4.4}$$

La correlación entre la posición de GPT+Search y el rank de Google para las URL compartidas es de r = 0,697, calculada sobre apenas 14 coincidencias de URL exacta, mientras que la correlación entre GPT sin Search y Google es de solo r = 0,230 sobre las 13 coincidencias. La correlación más alta se registra entre las dos modalidades de GPT: r = 0,808 sobre 310 coincidencias de URL, lo que indica que cuando ambas versiones del modelo citan las mismas webs, tienden a hacerlo en un orden muy similar.

En estas gráficas se puede observar la distribución del coeficiente de Pearson, la barra de color indica la diferencia en el ranking; y en las dos primeras las posiciones de Google se presentan en el eje y.



(a) GPT con Search **(b)** GPT sin Search

Figura 4.11: Pearson para Google

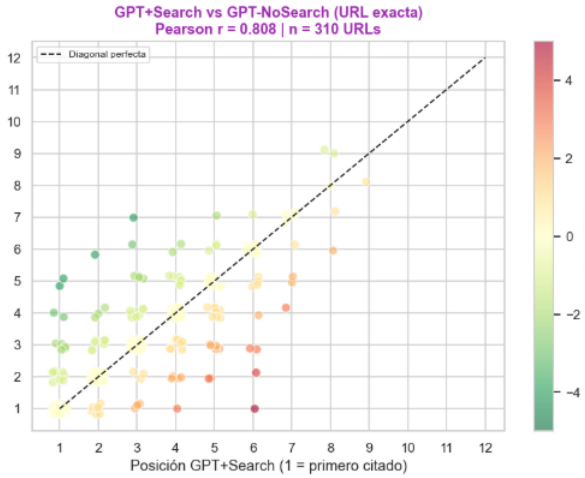


Figura 4.12: Coeficiente pearson para GPT

Examinando las diferencias en las posiciones se llegan a las siguientes conclusiones. Para cuantificar esta divergencia se emplea la diferencia media de posiciones, definida como:

$$\Delta_{\text{pos}} = \frac{1}{n}\sum_{i=1}^{n}(x_i - y_i) \tag{4.5}$$

En las coincidencias entre Google y GPT con Search la diferencia media es de 2,07 posiciones a favor de GPT con Search clasificando el 79 % de las coincidencias por encima y el 21 % como empate. Entre Google y GPT sin Search la diferencia es de 3,31 a favor de GPT clasificando el 85 % de veces por encima y el 8 % como empate. Por último, en el par de GPT con Search y GPT sin Search existe una diferencia media de 0, con 60 % de empate, un 21 % a favor de GPT con Search y un 19 % a favor de GPT sin Search.

Par de motores	**Dif. media**	**A favor de**	**Arriba**	**Empate**
Google vs GPT con Search	2,07	GPT con Search	79 %	21 %
Google vs GPT sin Search	3,31	GPT sin Search	85 %	8 %
GPT con Search vs GPT sin Search	0	—	21 %	60 %

Tabla 4.6: Diferencias en las posiciones de los dominios coincidentes entre motores

Dividiendo estos resultados por categorías en el caso del par de GPT con Search y GPT sin Search, por ser el que tiene mayor número de coincidencias, obtenemos que la categoría con un coeficiente de Pearson mayor es Banco y Finanzas y la de menor es Ocio.

Categoría	**Diferencia media**	**Coef. correlación Pearson**
Bancos y Finanzas	−0,08	0.990
Mascotas	−0,33	0.970
Moda y Ropa	+0,00	0.920
Salud y Medicina	+0,00	0.910
Inmuebles	+0,00	0.880
Deporte y Fitness	−0,04	0.850
Tecnología y Telecomunicaciones	+0,11	0.840
Transporte y Movilidad	+0,14	0.830
Turismo y Monumentos	+0,02	0.820
Servicios Profesionales	+0,75	0.810
Restaurantes y Gastronomía	+0,05	0.770
Supermercados y Alimentación	−0,35	0.720
Alojamiento y Hoteles	+0,00	0.690
Educación	−0,11	0.630
Ocio y Entretenimiento	−0,27	0.540

Tabla 4.7: Diferencia media de posiciones y correlación de Pearson por categoría (Los resultados positivos en la diferencia media van a favor de GPT con Search, los negativos a favor de GPT sin Search)

Cabe destacar las consultas con mayor número de coincidencias entre GPT con Search y GPT sin Search. Aunque en la figura 4.13 aparezcan dominios como wikipedia.org es para acortar las URLs, para la coincidencia se tiene en cuenta toda la URL.

Pregunta	Categoría	GPT+Search	GPT-NoSearch	N URLs compartidas	Diff media pos.
¿Cuáles son las marcas de ropa más famosas de España?	Moda y Ropa	✅1.zara.com | ✅2.mango.com | ✅3.pullandbear.com | ✅4.bershka.com | ✅5.massimodutti.com | ✅6.desigual.com | ✅7.stradivarius.com | ✅8.elcorteingles.es	✅1.zara.com | ✅2.mango.com | ✅3.massimodutti.com | ✅4.pullandbear.com | ✅5.bershka.com | ✅6.stradivarius.com | ✅7.desigual.com | ·8.adolfodominguez.com | ✅9.elcorteingles.es | ·10.sfera.com	8	-0.100000
¿Cuáles son las mejores tiendas de ropa online españolas?	Moda y Ropa	✅1.zara.com | ✅2.shop.mango.com | ✅3.pullandbear.com | ✅4.stradivarius.com | ✅5.bershka.com | ✅6.massimodutti.com | ✅7.asos.com | ·8.sprinter.es | ✅9.elcorteingles.es	✅1.zara.com | ✅2.shop.mango.com | ✅3.pullandbear.com | ✅4.bershka.com | ✅5.stradivarius.com | ✅6.massimodutti.com | ✅7.asos.com | ✅8.elcorteingles.es | ·9.sfera.com | ·10.desigual.com	8	0.100000
¿Cuáles son los equipos de fútbol más famosos de España?	Deporte y Fitness	✅1.realmadrid.com | ✅2.fcbarcelona.com | ✅3.atleticodemadrid.com | ✅4.sevillafc.es | ✅5.valenciacf.com | ✅6.realbetisbalompie.es | ✅7.athletic-club.eus | ✅8.realsociedad.eus	✅1.realmadrid.com | ✅2.fcbarcelona.com | ✅3.atleticodemadrid.com | ✅4.sevillafc.es | ✅5.valenciacf.com | ✅6.realbetisbalompie.es | ✅7.athletic-club.eus | ✅8.realsociedad.eus	8	0.000000
¿Qué lugares visitar en el Camino de Santiago?	Turismo y Monumentos	✅1.es.wikipedia.org | ✅2.es.wikipedia.org | ✅3.es.wikipedia.org | ✅4.es.wikipedia.org | ✅5.es.wikipedia.org | ✅6.es.wikipedia.org | ·7.es.wikipedia.org | ✅8.es.wikipedia.org	✅1.es.wikipedia.org | ✅2.es.wikipedia.org | ✅3.es.wikipedia.org | ✅4.es.wikipedia.org | ✅5.es.wikipedia.org | ✅6.es.wikipedia.org | ·7.es.wikipedia.org | ·8.es.wikipedia.org | ✅9.es.wikipedia.org	7	-0.100000
¿Cuáles son las universidades más famosas de España?	Educación	✅1.ub.edu | ✅2.ucm.es | ✅3.upm.es | ✅4.uv.es | ✅5.usal.es | ✅6.us.es | ·7.uam.es | ✅8.ugr.es	✅1.ub.edu | ✅2.ucm.es | ✅3.usal.es | ✅4.upm.es | ✅5.uv.es | ✅6.us.es | ✅7.ugr.es | ·8.unizar.es	7	0.100000
¿Cuáles son las islas más turísticas de España?	Turismo y Monumentos	✅1.es.wikipedia.org | ✅2.es.wikipedia.org | ✅3.es.wikipedia.org | ✅4.es.wikipedia.org | ·5.es.wikipedia.org | ✅6.es.wikipedia.org | ✅7.es.wikipedia.org	✅1.es.wikipedia.org | ✅2.es.wikipedia.org | ✅3.es.wikipedia.org | ✅4.es.wikipedia.org | ✅5.es.wikipedia.org | ✅6.es.wikipedia.org | ·7.es.wikipedia.org | ·8.es.wikipedia.org	6	0.300000
¿Cuáles son las agencias de viajes más populares de España	Servicios Profesionales	✅1.viajar.com | ✅2.logitravel.com | ·3.atrapalo.com | ✅4.viajes.carrefour.es | ✅5.bthetravelbrand.com | ✅6.nautaliaviajes.com | ✅7.travelplan.es	✅1.viajar.com | ✅2.logitravel.com | ✅3.viajes.carrefour.es | ✅4.bthetravelbrand.com | ✅5.nautaliaviajes.com | ·6.viajeselcorteingles.es | ✅7.travelplan.es | ·8.destinia.com	6	0.500000

Figura 4.13: Consultas con mayor coincidencia entre los GPT

4.2.5 Análisis profundo de clasificación de rankings

Finalmente, se llevó a cabo una inspección manual sobre un par de consultas de tipo ranking con el objetivo de evaluar si las listas generadas por GPT coinciden con los rankings presentes en las páginas web referenciadas por Google. Este análisis surge como consecuencia directa de uno de los patrones observados en los apartados anteriores: Google no devuelve rankings propios ordenando servicios o personas ante este tipo de consultas, sino que tiende a referenciar páginas externas que contienen dichos rankings en su interior. Resulta por tanto pertinente examinar si el contenido de esas páginas, guarda similitud con las listas que GPT genera de forma directa.

Para ello se accedió manualmente a varios de los resultados devueltos por Google y se extrajeron los rankings que contenían, comparándolos con las listas generadas por GPT con Search y GPT sin Search.

Los dos ejemplos analizados ilustran patrones distintos. En el caso de la consulta de “Res-

taurantes de comida rápida más famosos de España", tanto GPT con Search como GPT sin Search generan listas similares entre sí, McDonald's, Burger King, KFC, Telepizza, Pans & Company; con una elevada coincidencia en las primeras posiciones. Los rankings extraídos de los resultados de Google presentan mayor variabilidad entre sí dependiendo de la fuente consultada, aunque comparten un núcleo común de cadenas con GPT: McDonald's, Burger King, KFC y Telepizza aparecen en prácticamente todos los rankings. En este caso la convergencia entre sistemas es notable, lo que es coherente con el hecho de que se trata de entidades de mucha popularidad y presencia en la web y en el corpus de entrenamiento del LLM.

El caso de "Deportistas más importantes de la historia de España" revela un patrón diferente. GPT con Search y GPT sin Search coinciden en las primeras posiciones, Nadal, Pau Gasol, Fernando Alonso, Severiano Ballesteros; aunque divergen a partir de la cuarta posición: GPT con Search incluye a Carlos Sainz, mientras que GPT sin Search añade a Iker Casillas, Carles Puyol, Mireia Belmonte y Ruth Beitia, sugiriendo que el acceso a Internet introduce cierta actualización en las referencias más recientes. Los rankings de Google presentan mayor diversidad y longitud, incluyendo figuras como Indurain, Iniesta, Ángel Nieto, Carolina Marín o Marc Márquez que no aparecen en las primeras posiciones de GPT. En este caso la divergencia es más pronunciada, esto puede atribuirse tanto a la subjetividad de la consulta como a las diferencias en las fuentes que cada sistema prioriza para resolver preguntas de carácter valorativo.

En la consulta "¿Cuáles son los restaurantes con estrella Michelin más conocidos de España?", GPT con Search y GPT sin Search muestran una elevada coincidencia en las primeras posiciones, incluyendo restaurantes como El Celler de Can Roca, DiverXO, Arzak y Aponiente, que también aparecen de forma recurrente en las páginas posicionadas por Google. GPT con Search amplía ligeramente la respuesta incorporando restaurantes como Martín Berasategui, Azurmendi y Quique Dacosta, alineándose más estrechamente con los rankings presentes en las webs de referencia mostradas por Google. Por su parte, GPT sin Search ofrece una lista más reducida y menos diversa, centrada principalmente en los restaurantes con mayor notoriedad histórica y mediática. Los resultados de Google presentan una mayor amplitud y variabilidad entre fuentes, aunque mantienen un núcleo común muy consistente con las respuestas de GPT. En este caso la convergencia entre sistemas es elevada, lo que sugiere que los restaurantes Michelin más reconocidos poseen una fuerte presencia tanto en la web como en los datos de entrenamiento del modelo, reduciendo las diferencias entre respuestas generadas con y sin acceso a búsqueda en tiempo real.

Aunque limitado en alcance este análisis nos da alguna pista sobre la convergencia entre GPT y Google, divergiendo en consultas de naturaleza valorativa o subjetiva (la selección y el orden dependen del criterio de la fuente y de los sesgos de cada sistema) y convergiendo más en consultas sobre entidades objetivas y de alta notoriedad.

4.3 Limitaciones del análisis

Los resultados presentados en los apartados anteriores deben interpretarse teniendo en cuenta una serie de limitaciones metodológicas y en los resultados que condicionan el alcance y la generalización de las conclusiones que se desarrollaran a continuación.

En primer lugar, el análisis de solapamiento se basa exclusivamente en coincidencias de URL y dominio normalizados, sin incorporar ninguna evaluación de la relevancia o calidad de los resultados. Determinar cuál de los sistemas proporciona resultados más útiles o precisos para el usuario requeriría una valoración humana de cada resultado que queda fuera del alcance del presente trabajo. Con las métricas utilizadas, este análisis de utilidad y relevancia para los usuarios queda determinado a únicamente recomendaciones de uso según los patrones de respuesta de los sistemas evaluados.

En segundo lugar, los resultados están acotados temporalmente al periodo en que se recogieron los datos. Tanto el índice de Google como el conocimiento paramétrico de GPT-4o mini (extendido hasta octubre de 2023) corresponden a un momento concreto, y los patrones observados pueden variar con el tiempo debido a la naturaleza dinámica de los algoritmos de búsqueda y a las actualizaciones periódicas de los modelos de lenguaje.

En tercer lugar, el estudio se acota al mercado español y a las categorías temáticas seleccionadas, por lo que los resultados habiendo cumplido los objetivos del estudio no son directamente generalizables a otros idiomas, mercados geográficos o dominios temáticos. La representatividad del pool de consultas, aunque amplia, está condicionada por el proceso de generación descrito en el Capítulo 3.

En cuarto lugar, el análisis cualitativo de rankings del apartado 4.2.5 se basa en un número muy reducido de ejemplos inspeccionados manualmente, por lo que sus conclusiones tienen carácter ilustrativo y exploratorio, no estadísticamente representativo. El hecho de tener que ser llevado a cabo manualmente dificulta mucho la tarea de escalarlo.

Por último, el estudio evalúa únicamente dos sistemas de recuperación basados en LLM, GPT-4o mini con y sin acceso a Internet, sin contemplar otros modelos como Gemini, LLaMA o DeepSeek, cuyo comportamiento podría ser distinto del observado. Asimismo, como motor de búsqueda solo se evalúa a Google, sin contemplar otros como Bing, Baidu...

Conclusiones y líneas futuras

5.1 Conclusiones

El desarrollo de este Trabajo de Fin de Grado ha permitido cumplir satisfactoriamente los objetivos planteados inicialmente. Se ha investigado en profundidad el funcionamiento de los modelos de lenguaje y los motores de búsqueda tradicionales en el campo de la recuperación de información. Se han evaluado tres sistemas distintos revelando diferencias significativas en términos de diversidad de dominios, orden de priorización y grado de coincidencia en los resultados. Asimismo, se ha desarrollado e implementado una herramienta web funcional que permite a los usuarios realizar consultas comparativas en tiempo real, visualizar métricas de coincidencia y analizar las diferencias en el posicionamiento de las URLs. A partir de los resultados obtenidos, se presentan a continuación las principales conclusiones sobre el rendimiento comparado de estos sistemas y sus implicaciones para el ecosistema digital de visibilidad y descubrimiento de información.

El primer hallazgo y más robusto es que los motores de búsqueda tradicionales y los modelos de lenguaje de gran escala producen resultados fundamentalmente distintos antes las mismas consultas. Atendiendo a los índices de Jaccard presenciados en las comparativas de los LLM con Google se observan valores sorprendentemente bajos, que no alcanzan ni el 0,05. Esto confirma empíricamente lo apuntado por estudios previos vistos en el Estado del Arte, que encontraban solapamientos entre ChatGPT y Google de aproximadamente el 10 % en contextos anglosajones [66] [64].

Esta divergencia no debe catalogarse como un fallo en cualquiera de los sistemas, sino evidencia de un comportamiento y funcionamiento distinto entre los mismos. Google opera sobre un índice actualizado de la web y ordena los resultados mediante el algoritmo de PageRank previamente explicado. Por su parte GPT prioriza fuentes de referencia estables y de alta autoridad percibida debido a los patrones estadísticos aprendidos en el entrenamiento.

A pesar de que el acceso a Internet mejora las diferencias entre GPT-4o mini y Google no elimina la divergencia. Es cierto que la activación de la búsqueda web ayuda a recoger fuentes más actualizadas, verificables y fiables pero esto no implica que se produzca una convergencia con los resultados de Google. Esta falta de convergencia puede atribuirse a que el acceso a Internet de los LLM no reproduce el proceso de indexación y ranking de motores de búsqueda, únicamente ofrece un mayor campo de información para que el LLM recupere la información solicitada.

El análisis de posiciones muestra que esta opción aporta principalmente nuevas fuentes sin alterar mucho el orden de las fuentes ya conocidas por su entrenamiento. Este hallazgo indica que el conocimiento paramétrico del modelo aprendido en el entrenamiento actúa como sesgo

estructural que no se consigue neutralizar del todo.

¿La popularidad de las consultas importa realmente? La respuesta es simple, sin embargo, encierra una gran complejidad reflexiva. Comparando los dos tipos de LLM analizados la popularidad actúa como un factor de mejora claro aumentando los valores de las métricas considerablemente. No obstante, comparando los LLM con Google los valores de las métricas utilizadas caen considerablemente ante la presencia y el estudio de este segundo subconjunto.

Esto se debe a que las principales diferencias entre los dos sistemas de GPT radican en la actualización de la información: si no se activa la búsqueda web, el modelo depende únicamente de los datos de entrenamiento. En consultas de alta popularidad, la falta de actualización suele ser menos relevante porque la información para responder ese tipo de preguntas probablemente ya estaba incluida en los datos de entrenamiento.

Uno de los patrones más consistentes del estudio es la tendencia de GPT, tanto con Search como sin Search, a citar fuentes primarias, las webs propias de los establecimientos (o en su defecto artículos de wikipedia referenciando elementos únicos) frente a la tendencia de Google de priorizar directorios y guías, fuentes secundarias. Esta diferencia tiene implicaciones directas para las estrategias de visibilidad de los negocios. En Google el posicionamiento depende de plataformas de reseñas y directorios con alta autoridad SEO, mientras que en el ecosistema de los LLM la visibilidad parece relacionarse más con la prominencia y la autoridad de la propia web del negocio.

Aparte estas diferencias tienen un impacto en las consultas de usuarios. Por ejemplo, si quieres comparar servicios, establecimientos o opciones contrastando páginas específicas de ranking es mejor utilizar Google, al preguntar por el mejor restaurante de comida china en Madrid, recibirás en la mayoría de casos webs con listas y reseñas de otros usuarios. Si, por otro lado, quieres una respuesta más clara y directa, establecimientos o servicios propios, es mejor utilizar GPT con acceso a Internet para obtener información más directa y actualizada que sin activar la opción de búsqueda web.

5.2 Líneas de trabajo futuro

Los resultados obtenidos y las limitaciones identificadas a lo largo de este trabajo abren varias líneas de investigación para ser desarrolladas en trabajos futuros.

- La primera y más directa sería complementar este análisis con una **evaluación de relevancia y calidad intrínseca de los resultados**. Este estudio se ha llevado a cabo utilizando métricas de solapamiento y posición cuantificando similitudes y diferencias entre sistemas pero no alcanza a proporcionar resultados como que sistema tiene mayor utilidad o mayor calidad en las respuestas. Un trabajo futuro podría incorporar valoraciones humanas sobre muestras de resultados de cada sistema, permitiendo así ese

análisis complementario.

- Una segunda línea de trabajo sería implementar **comparaciones de más sistemas de recuperación de información**. En vez de utilizar solo Google como motor de búsqueda y GPT-4o mini como modelo de lenguaje implementar extras como Bing, Yandex, Gemini, Llama... Estableciendo así una comparación más rica y variada para los usuarios.

- Una tercera línea consiste en **ampliar el estudio a otros idiomas y mercados geográficos**, para determinar si los patrones extraídos en el mercado español son generalizables. A su vez, en vez de ampliar se podría centrar el estudio en provincias o en comunidades autónomas españolas, para ver como varían dentro del propio mercado español los patrones observados.

- Otra línea de investigación relevante es el estudio de la **optimización para motores de generación (GEO)** y la comparación con el SEO. Los resultados obtenidos en el presente trabajo sugieren que los factores que determinan la visibilidad de un negocio en los LLM no son los mismos que determinan su posicionamiento en Google, lo que abre un campo a explorar en la presencia de los negocios en los LLM.

- Finalmente, otra línea de trabajo es el **análisis comparativo longitudinal**. Los índices de Google y de los LLM evolucionan continuamente, con lo cual replicar este experimento en diferentes momentos temporales para determinar la evolución de la divergencia observada sería de gran interés.

Bibliografía

[1] StatCounter, "Search engine market share worldwide," 2026. Accedido: 2026-05-02.

[2] X. Shen, Z. Chen, M. Backes, and Y. Zhang, "In chatgpt we trust? measuring and characterizing the reliability of chatgpt," *arXiv preprint arXiv:2304.08979*, 2023.

[3] J. Schmidhuber, "Annotated history of modern ai and deep learning," 2022.

[4] H. Wang and B. Raj, "On the origin of deep learning," 2017.

[5] J. McCarthy, M. Minsky, N. Rochester, and C. Shannon, "A proposal for the dartmouth summer research project on artificial intelligence," 1955.

[6] A. Newell and H. A. Simon, "The logic theory machine and the general problem solver," *IRE Transactions on Information Theory*, 1957.

[7] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, "Learning representations by back-propagating errors," *Nature*, vol. 323, pp. 533–536, 1986.

[8] M. Campbell, A. J. Hoane, and F. hsiung Hsu, "Deep blue," *Artificial Intelligence*, vol. 134, pp. 57–83, 2002.

[9] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[10] G. E. Hinton, S. Osindero, and Y.-W. Teh, "A fast learning algorithm for deep belief nets," *Neural Computation*, vol. 18, no. 7, pp. 1527–1554, 2006.

[11] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," in *NeurIPS*, 2012.

[12] I. Goodfellow *et al.*, "Generative adversarial nets," in *NeurIPS*, 2014.

[13] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, 2015.

[14] Y. Guo *et al.*, "A decade of deep learning: A survey on the magnificent seven," 2024.

[15] D. Silver *et al.*, "Mastering the game of go with deep neural networks and tree search," *Nature*, vol. 529, pp. 484–489, 2016.

[16] A. Vaswani *et al.*, "Attention is all you need," in *NeurIPS*, 2017.

[17] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "Bert: Pre-training of deep bidirectional transformers for language understanding," 2018.

[18] A. Radford *et al.*, "Improving language understanding by generative pre-training," 2018.

[19] W. X. Zhao *et al.*, "A survey of large language models," 2023.

[20] T. Brown *et al.*, "Language models are few-shot learners," in *NeurIPS*, 2020.

[21] L. Ouyang *et al.*, "Training language models to follow instructions with human feedback," *NeurIPS*, 2022.

[22] S. Casper *et al.*, "Open problems and fundamental limitations of reinforcement learning from human feedback," 2023.

[23] OpenAI, "Gpt-4 technical report," tech. rep., OpenAI, 2024.

[24] S. Bubeck, V. Chandrasekaran, R. Eldan, J. Gehrke, E. Horvitz, E. Kamar, P. Lee, Y. T. Lee, Y. Li, S. Lundberg, H. Nori, *et al.*, "Sparks of artificial general intelligence: Early experiments with gpt-4," *arXiv preprint arXiv:2303.12712*, 2023.

[25] Google DeepMind, "Gemini: A family of highly capable multimodal models," tech. rep., Google DeepMind, 2024.

[26] M. Reid *et al.*, "Gemini 1.5: Unlocking multimodal understanding at scale," tech. rep., Google DeepMind, 2024.

[27] Anthropic, "Claude 3 model card," tech. rep., Anthropic, 2024.

[28] xAI, "Grok model overview," 2024. Available at: https://x.ai.

[29] DeepSeek-AI, "Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning," 2024.

[30] H. Touvron, L. Martin, K. Stone, *et al.*, "Llama: Open and efficient foundation language models," *arXiv preprint arXiv:2302.13971*, 2023.

[31] A. Q. Jiang, A. Sablayrolles, *et al.*, "Mistral 7b," *arXiv preprint arXiv:2310.06825*, 2023.

[32] Alibaba Cloud, "Qwen technical report," 2023.

[33] A. James and J. Kannan, "A survey on information retrieval models, techniques and applications," *Advances in Networks*, 2017.

[34] Z. Zhao *et al.*, "A survey of model architectures in information retrieval," 2025.

[35] K. Farivar, "Semantic search for information retrieval," 2025.

[36] M. Franceschet, "Pagerank: Standing on the shoulders of giants," *arXiv*, 2010.

[37] S. Brin and L. Page, "The anatomy of a large-scale hypertextual web search engine," 1998.

[38] W. X. Zhao *et al.*, "Dense text retrieval based on pretrained language models: A survey," *ACM Transactions on Information Systems*, 2022.

[39] V. Karpukhin *et al.*, "Dense passage retrieval for open-domain question answering," in *EMNLP*, 2020.

[40] Stackscale, "Archie, el primer motor de búsqueda de internet." https://www.stackscale.com/es/blog/archie-motor-busqueda-internet/, 2021. Consultado: 2026-05-01.

[41] M. F. P. Mancebo, "Gopher." https://www.uv.es/ genaro/morella/gopher.htm. Universitat de València. Consultado: 2026-05-01.

[42] C. Culligan, "A brief history of search engines." https://www.perfectsearchmedia.com/blog/google-brief-history-search-engines, 2019. Perfect Search Media. Consultado: 2026-05-01.

[43] Arimetrics, "Yahoo: definición, significado e historia." `https://www.arimetrics.com/glosario-digital/yahoo`, 2020. Consultado: 2026-05-01.

[44] LIS Academy, "The evolution of search engines: From archie to google," 2025.

[45] Rellify, "The evolution of search engines: From archie to answer engines," 2025.

[46] Search Insights Academy, "How search engines work: Crawling, indexing and ranking," 2025.

[47] Sixsoftmedia, "The history of search engines year wise: From archie to ai," 2025.

[48] Searchable, "How search engines work: Crawling, indexing, ranking, and the ai shift," 2025.

[49] WebSearchAPI, "How search engines really work: Crawling, indexing, ranking, and serving," 2025.

[50] OPositive, "How search engines work: Crawling, indexing and ranking explained," 2025.

[51] "The effectiveness of search engine optimization (seo) in marketing: A meta-analysis study," 2024.

[52] T. K. Naab *et al.*, "The influence of search engine optimization on google's results," *ACM*, 2021.

[53] R. Demsyn-Jones, "Measurement and applications of position bias in a marketplace search engine," 2022.

[54] R. Epstein and J. Li, "Can biased search results change people's opinions? a replication of the search engine manipulation effect (seme)," *PLOS ONE*, 2024.

[55] Y. Gao *et al.*, "Retrieval-augmented generation for large language models: A survey," 2023.

[56] C. Sharma, "Retrieval-augmented generation: A comprehensive survey of architectures, enhancements, and robustness frontiers," 2025.

[57] L. Huang *et al.*, "A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions," 2023.

[58] K. M. Caramancion, "Large language models vs. search engines: Evaluating user preferences across varied information retrieval scenarios," 2024.

[59] Zhu *et al.*, "Evolving paradigms in task-based search and learning: A comparative analysis of traditional search engine with llm-enhanced conversational search system," 2024.

[60] M. Fernández-Pichel *et al.*, "Evaluating search engines and large language models for answering health questions," *npj Digital Medicine*, 2025.

[61] Y. Ren *et al.*, "Comparing large language models and search engine responses to common orthodontic questions," *PLOS ONE*, 2025.

[62] Y. Gao *et al.*, "Errors in ai-assisted retrieval of medical literature: A comparative study," *arXiv preprint arXiv:2026.22344*, 2026.

[63] K. Wu *et al.*, "An automated framework for assessing how well large language models cite medical references," *Nature Communications*, 2025.

[64] Ahrefs, "Only 12 % of ai cited urls rank in google's top 10 for the original prompt," 2025.

[65] Chatoptic, "Seo ≠ geo: Only 62 % overlap between google ranking and chatgpt visibility," 2025.

[66] Profound, "The surprising gap between chatgpt and google: Why traditional seo isn't enough," 2025.

[67] SparkToro, "New research: Google search grew 20 %+ in 2024; receives 373x more searches than chatgpt," 2025.

[68] J. M. M. Rodríguez, "Diseño de una herramienta para el análisis comparativo de la búsqueda de información entre modelos de lenguaje y buscadores tradicionales en españa," 2026. Repositorio GitHub. Disponible en: `https://github.com/ChemaM19R/TFG_Comparacion_Google_GPT-4oMINI`.

[69] DataForSEO, "Dataforseo — search engine results api," 2024.

[70] Glassdoor, “Sueldo: Junior data engineer en españa,” 2026.

Anexos

A Aspectos éticos, económicos, sociales y ambientales

A.1 Introducción

Este Trabajo Fin de Grado se ubica en el sector de los sistemas telemáticos e inteligencia artificial, abordando la comparativaentre dos sistemas distintos de recuperación de información en Internet: los motores de búsqueda tradicionales y los modelos de lenguaje de gran escala. Tiene un carácter analítico y empírico, sin implicar el desarrollo de la infraestructura física ni la producción de hardware, lo que limita su impacto ambiental directo. No obstante, el uso de APIs externas y la naturaleza de la trecnología estudiada plantean una serie de aspectos éticos, sociales, económicos y ambientales que mercen ser identificados y analizados.

Como ya se ha visto en los objetivos, este trabajo pretende resolver la falta de evidencia empírica sobre las diferencias de ambos sistemas de recuperación de información en el contexto español. Los principales grupos de interés afectados son los usuarios finales de sistemas de búsqueda, actualmente la práctica totalidad de la población con acceso a Internet, propietarios de negocios y servicios afectados por su visibilidad en Internet, investigadores y profesionales del sector, y por último empresas tecnológicos que desarrollan y operan los sistemas evaluados.

A.2 Descripción de impactos relevantes relacionados con el proyecto

A partir del análisis del contexto del trabajo, se identifican los siguientes impactos:

- **Sesgos en la recuperación de la información y la visibilidad digital:** El estudio expone que tanto uno como otro los sistemas que se evalúan presentan sesgos sistemáticos en su selección y ordenación de los resultados. En el caso de Google, esto se atribuye al SEO y puede favorecer a negocios con mayores recursos para invertir en este ámbito frenet a otros cono contenido igualmente relevante. En el caso de los LLM, los sesgos se

atribuyen al corpus de entrenamiento penalizando negocios locales con menor presencia digital histórica. Ambos tipos de sesgo tienen como denominador común un mismo grupo afectado, los pequeños negocios, autónomos y servicios locales con pocos recursos.

- **Privacidad y protección de datos:** Al utilizar APIs externas en el proceso de obtención de resultados y de la herramienta web el uso de dichas APIs implica la transmisión de información a servidores externos, con las implicaciones que ellos conlleva en materia de protección de datos. Este aspecto debería ser abordado mediante una política de privacidad adecuadad en un eventual despliegue de la herramienta web en producción cuidando los datos que los usuarios introducen en las consultas. La normativa aplicable incluye el Reglamento General de Protección de Datos (RGPD, Reglamento UE 2016/679) y la Ley Orgánica 3/2018 de Protección de Datos Personales y garantía de los derechos digitales (LOPDGDD).

- **Fiabilidad y desinformación:** Los LLM, como bien se ha podido observar en el estudio, tienden a generar respuestas y a citar fuentes con aparente confianza incluso cuando pueden ser incorrectas. Recomendación de establecimientos cerrados o URLs inexistentes (example.com en el caso de GPT sin web search). El riesgo de desinformación afecta a los usuarios, incitándoles a tomar decisiones incorrectas y a la reputación de los negocios, a través de menciones incorrectas. Este aspecto, que queda fuera del alcance del estudio, es de especial relevancia ética en dominios sensibles como la salud o los servicios de emergencia.

- **Consumo energético y huella de carbono:** El entrenamiento y la inferencia de los LLM conllevan un consumo energético significativo. En el presente trabajo se han realizado más de 30000 petciones a APIs durante el experimento implicando un consumo computacional no despreciable en los centros de datos de los proveedores. Este impacto se enmarca en la preocupación actual por la huella de carbono de la IA, reconocida por organismos como la Agencia Internacional de la Energía (AIE).

- **Impacto económico sobre el ecosistema de búsqueda:** El trabajo contribuye a documentar empíricamente la divergencia entre los resultados de los LLM y los de Google. Este fenómeno tiene implicaciones económicvas directas en el ecosistema digital pudiendo llegar a transformar los modelos de negocio basados en el posicionamiento SEO, una industria que a nivel global mueve mucho dinero.

A.3 Análisis detallado de alguno de los principales impactos

Para este análisis más detallado se han seleccionado los impactos 1 y 3, al ser los más relacionados con el trabajo y los de mayor relevancia ética y social.

Sesgos en la recuperación de información y equidad en la visibilidad digital

Los resultados empíricos del estudio confirman que los sistemas analizados priorizan distintos tipos de fuentes a la hora de responder a las consultas. Google tiende a priorizar fuentes secundarias y GPT primarias. Esta diferencia estructural implica que la visibilidad de un neocio en cada uno de los sitemas depende de factores diferentes e inaccesibles para pequeños propietarios sin conocimientos técnicos ni recursos para invertir en optimización digital.

Esta asimetría plantea un dilema ético relevante. Los sistemas de recuperación de información calcan y acrecientan las desigualdades preexistentes en el ecosistema digital. Un negocio con recursos tendrá mayor presencia digital que uno con menor capital digital pero igual o incluso más competente. Este hehco no atienede a la calidad real de su servicio, únicamente a sus recursos y conocimientos. La normativa aplicable en este ámbito incluye el Reglamento europeo de mercados digitales (Digital Markets Act, DMA) o las directrices de transparencia algorítmica promovidas por la Comisión Europea en el marco de la Ley de Servicios Digitales (DSA).

Una posible medida para reducir y mitigar este impacto en este contexto sería añadir en la herramienta web desarrollada un indicador de diversidad de las fuentes, para que los usuarios identifiquen si los resultados están dominados por unas pocas plataformas o reflejan una representación de negiocios locales mucho más amplia.

Fiabilidad y desinformación

El riesgo de alucinaciones en los LLM tiene implicaciones éticas cuando se utilizan estos sistemas como herramienta de búsqueda de servicios locales. Como se ha podido observar un LLM puede aportar URLs inexistente o con información desactualizada sin que el usuario pueda detectarlo de una manera sencilla.

Es por esto que ante la ausencia de una verificación de la existencia y actualidad de los establecimientos citados, el riesgo de desinformación persiste. Desde un punto de vista ético sería interesante introducir mecxanismos de verificación automática de las URLs citadas por el LLM en la herramienta web, para así reducir el riesgo de que los usuarios actúen sobre inforamción incorrecta.

A.4 Trasfondos

El presente trabajo contribuye al conocimiento empírico sobre el comportamiento de los sistemas de recuperación de información, un campo con implicaciones sociales, económicas y éticas de creciente relevancia. El trabajo ha sido realizado respetando los principios de honestidad e integridad académica, empleando datos generados de forma automatizada sin información personal de usuarios reales y citando las fuentes utilizadas conforme a las normas de propiedad intelectual vigentes.

El transfondo social del trabajo es documentar y cuantificar las diferencias y similitudes entre

paradigmas de recuperación de información, contribuyendo a esclarecer el funcionamiento de estos sistemas y proporcionando a usuarios información valiosa para toamr decisiones informadas sobre el uso de cada herramienta. Además, la herramienta web desarrollada permite a propietarios de negocio evaluar su visibilidad en los distintos sistemas sin necesidad de tener conocimientos técnicos avanzados.

El impacto ambiental depende del consumo energético asociado a las APIs externas, con lo cual es indirecto y limitado.

En cuanto al económico, su alcance está condicionado por las limitaciones de generalización descritas en la memoria, a pesar de ser relevante para el ecosistema del marketing digital.

En conjunto, contribuye al bienestar social mediante la generación de conocimiento empírico de utilidad pública y abre líneas de investigación relevantes sobre los sistemas de rescuperación de información en esta nueva era tecnológica en la que nos adentramos.

B Presupuesto económico

Con el fin de estimar los recursos empleados durante el desarrollo del Trabajo de Fin de Grado, a continuación se presenta el presupuesto económico asociado al proyecto. Este presupuesto contempla los costes de mano de obra correspondientes al tiempo dedicado a la investigación, el desarrollo de la herramienta web, la recopilación y análisis de datos, y la redacción de la memoria. Asimismo, se incluyen los costes de recursos materiales (equipamiento informático y software) y servicios externos (acceso a APIs de Google y OpenAI, servicios de almacenamiento y computación).

Esta estimación no pretende reflejar un coste comercial del proyecto, sino proporcionar una valoración razonable y justificada de los recursos utilizados, conforme a criterios habituales de ingeniería y gestión de proyectos. El coste horario de la mano de obra se ha estimado a partir de referencias salariales públicas correspondientes a un Ingeniero de Datos Junior en España, tomando como referencia un salario bruto anual medio de 25.000 [70]. Asumiendo una jornada laboral estándar, este valor se traduce en un coste aproximado de 12 euros/hora, que se adopta como criterio conservador para el presente presupuesto.

COSTE DE MANO DE OBRA		**Horas**	**€/hora**	**Total**
Desarrollo del proyecto		360	12,00 €	4.320,00 €
RECURSOS MATERIALES	**Precio**	**Meses**	**Años amort.**	**Total**
HP Elitebook 840 g5	300,00 €	9	4	56,25 €
APIs (LLM y búsqueda)	120,00 €	9	—	120,00 €
Total recursos materiales				**176,25 €**
COSTES INDIRECTOS				
Gastos generales (15 % sobre CD)				674,44 €
Beneficio industrial (6 % sobre CD + GG)				310,24 €
SUBTOTAL				**5.480,93 €**
IVA (21 %)				1.150,99 €
TOTAL PRESUPUESTO				**6.631,92 €**

Tabla 5.1: Presupuesto económico del Trabajo Fin de Grado

C Repositorio de Código

El código fuente, los conjuntos de datos y los scripts desarrollados a lo largo del presente trabajo se encuentran organizados en un repositorio con la siguiente estructura de directorios:

Análisis — Contiene los notebooks de Jupyter empleados para el análisis comparativo de los resultados. El fichero `analisis_comparativo_definitivo.ipynb` recoge el análisis principal sobre el subconjunto de las 200 consultas, mientras que `comparativa_3_motores.ipynb` implementa la comparativa directa entre los tres sistemas evaluados para las 10000 primeras consultas.

Datasets — Almacena todos los conjuntos de datos generados y utilizados en el experimento, organizado en dos subcarpetas:

- `10000_consultas` — Contiene los ficheros Excel con las preguntas originales (`10000_preguntas.xlsx`), las consultas reformuladas (`10000_reformuladas.xlsx`) y los resultados obtenidos de cada sistema (`10000_gptsearch_google.xlsx` y `10000_gptsinsearch.xlsx`). La subcarpeta `Reformulacion` incluye los ficheros JSONL del proceso de reformulación por lotes mediante la API de OpenAI (`batch_reformulacion_10000.jsonl`, `batch_resultados_10000.jsonl`) y el script de procesamiento correspondiente (`procesar_batch_openai.py`).
- `200_consultas_populares` — Contiene los resultados del subconjunto de 200 consultas de alta popularidad, con ficheros equivalentes para las modalidades con y sin búsqueda web (`200_gptsearch_google.xlsx` y `200_gptsinsearch.xlsx`).

Herramienta_web — Contiene los dos ficheros que componen la herramienta de comparativa interactiva: el backend desarrollado en Flask (`app.py`) y el frontend de página única (`index.html`), descritos en detalle en el apartado de desarrollo de la memoria.

Obtencion_respuestas — Contiene los scripts Python utilizados para la obtención automatizada de resultados de cada uno de los tres sistemas evaluados: `respuestas_google.py` para la consulta a la API de DataForSEO, `respuestas_gpt4-omini_search.py` para GPT-4o mini con búsqueda web activada y `respuestas_gpt4-omini_sinsearch.py` para GPT-4o mini sin acceso a Internet. Estos archivos han sido reutilizados, primeramente para el pool de las 10000 consultas y más tarde para el subconjunto de las 200 preguntas.

El repositorio completo del proyecto se encuentra disponible en GitHub [68].